

**TRƯỜNG ĐẠI HỌC CÔNG NGHỆ
ĐẠI HỌC QUỐC GIA HÀ NỘI**



BÁO CÁO MÔN HỌC

Ngành: Trí Tuệ Nhân Tạo

Sinh viên thực hiện:

Trần Quốc Khánh – 23020387

Nguyễn Văn Linh – 23020395

Hoàng Ngọc Nam – 23020403

Nguyễn Hữu Hoàng Nam – 23020405

Giảng viên hướng dẫn:

PSG.TS Nguyễn Phương Thái

TS. Trần Hồng Việt

Tóm tắt nội dung

Tóm Tắt

Sự phát triển của các Mô hình Ngôn ngữ Lớn (LLMs) đã mở ra tiềm năng chưa từng có trong việc hiểu và tạo ra văn bản giống người, đặc biệt là trong lĩnh vực tài chính. Tuy nhiên, những thách thức xuất phát từ nhu cầu về dữ liệu gắn nhãn lớn và yêu cầu cấp thiết về bảo mật dữ liệu vẫn còn tồn tại. Việc tạo ra dữ liệu tổng hợp chất lượng cao nổi lên như một hướng đi hứa hẹn để giải quyết các vấn đề này.

Nghiên cứu này đề xuất một phương pháp mới, được đặt tên là "Reinforcement Prompting", để giải quyết những thách thức trên. Chiến lược này sử dụng một mạng chính sách (policy network) với vai trò là Bộ chọn (Selector) để tạo các gợi ý (prompts), và một LLM với vai trò là Bộ thực thi (Executor) để tạo ra dữ liệu tài chính tổng hợp. Quá trình tạo ra dữ liệu tổng hợp này giúp đảm bảo quyền riêng tư dữ liệu và giảm sự phụ thuộc vào các bộ dữ liệu gắn nhãn trong thế giới thực.

Tính hiệu quả của phương pháp được xác thực thông qua các đánh giá thực nghiệm. Kết quả cho thấy các mô hình được huấn luyện trên dữ liệu tổng hợp được tạo ra bằng phương pháp này thể hiện hiệu suất đáng kinh ngạc khi so sánh với các mô hình được huấn luyện trên dữ liệu tài chính thực tế, qua đó thu hẹp khoảng cách về hiệu suất.

Nghiên cứu này cung cấp một giải pháp mới cho các thách thức về quyền riêng tư dữ liệu và sự khan hiếm dữ liệu gắn nhãn trong phân tích cảm xúc tài chính, mang lại những tiến bộ đáng kể trong lĩnh vực học máy trong tài chính.

Từ khóa: Reinforcement prompting, học tăng cường, dữ liệu tổng hợp, mô hình ngôn ngữ lớn, phân tích cảm xúc tài chính, học máy.

Abstract

Abstract

The emergence of Large Language Models (LLMs) has unlocked unprecedented potential for comprehending and generating human-like text, fueling advances in the finance domain. Nevertheless, challenges stemming from the necessity for extensive labeled data and the imperative for data privacy remain. The generation of high-quality synthetic data emerges as a promising avenue to circumvent these issues.

This thesis introduces a novel methodology, named "Reinforcement Prompting", to address these challenges. Our strategy employs a policy network as a Selector to generate prompts, and an LLM as an Executor to produce financial synthetic data. This synthetic data generation process preserves data privacy and mitigates the dependency on real-world labeled datasets.

We validate the effectiveness of our approach through experimental evaluations. Our results indicate that models trained on synthetic data generated via our approach exhibit competitive performance when compared to those trained on actual financial data, thereby bridging the performance gap.

This research provides a novel solution to the challenges of data privacy and labeled data scarcity in financial sentiment analysis, offering considerable advancement in the field of financial machine learning.

Keywords: Reinforcement prompting, reinforcement learning, synthetic data, large language model, financial sentiment analysis, machine learning.

Mục lục

Tóm Tắt	1
Abstract	1
Danh Mục Hình Ảnh	3
Danh Mục Bảng	4
Danh Mục Từ Viết Tắt	5
1 Giới Thiệu	6
1.1 Bối cảnh và Tính cấp thiết của đề tài	6
1.2 Mục tiêu nghiên cứu	6
1.3 Đối tượng và Phạm vi nghiên cứu	7
1.3.1 Đối tượng nghiên cứu	7
1.3.2 Phạm vi nghiên cứu	7
1.4 Phương pháp nghiên cứu	8
1.4.1 Nghiên cứu lý thuyết	8
1.4.2 Thực nghiệm	8
1.5 Ý nghĩa khoa học và thực tiễn của đề tài	9
1.5.1 Ý nghĩa khoa học	9
1.5.2 Ý nghĩa thực tiễn	9
1.6 Cấu trúc báo cáo	9
1.7 Mô hình Ngôn ngữ Lớn (LLMs)	10
1.7.1 Giới thiệu chung về LLMs	10
1.7.2 LLMs trong lĩnh vực tài chính	10
1.7.3 Những thách thức của LLMs trong tài chính	10
1.8 Học Tăng Cường (Reinforcement Learning)	11
1.8.1 Các khái niệm cơ bản	11
1.8.2 Ứng dụng Học Tăng Cường trong tạo sinh văn bản	11
1.9 Dữ liệu tổng hợp (Synthetic Data)	11
1.9.1 Khái niệm và lợi ích	11
1.9.2 Các phương pháp tạo sinh dữ liệu tổng hợp	12
1.10 Phân tích cảm xúc tài chính	12

2	Phương Pháp Đề Xuất: Reinforcement Prompting	13
2.1	Tổng quan kiến trúc hệ thống	13
2.2	Các thành phần của hệ thống	14
2.2.1	Danh sách từ khóa (Keywords Vocabulary) và Mẫu câu lệnh (Prompt Template)	14
2.2.2	Mạng Selector-Executor	14
2.3	Quá trình tối ưu hóa và hàm thưởng	15
2.3.1	Mục tiêu tối ưu hóa	15
2.3.2	Môi trường và hàm thưởng (Environment and Reward Function)	16
2.4	Các thước đo đánh giá chất lượng dữ liệu tổng hợp	16
2.4.1	Thước đo STY (Stylistic Resemblance)	16
2.4.2	Thước đo ACR (Accuracy of Sentiment Prediction)	17
2.4.3	Thước đo LXC (Lexical Diversity and Financial Terminology Inclusion)	17
2.5	Tạo sinh prompt tối ưu và đánh giá	17
3	Thực Nghiệm và Đánh Giá	19
3.1	Thiết lập thực nghiệm	19
3.1.1	Bộ dữ liệu	19
3.1.2	Lựa chọn mô hình ngôn ngữ	21
3.1.3	Thông số huấn luyện	21
3.2	Kết quả thực hiện Reinforcement Prompting	22
3.2.1	Quá trình hội tụ của Agent	22
3.2.2	Các bộ từ khóa được chọn và prompt tối ưu	22
3.2.3	Mẫu dữ liệu tổng hợp được tạo ra	23
3.3	Đánh giá trên tác vụ phân tích cảm xúc	23
3.3.1	Phân tích trên bộ dữ liệu Twitter Financial Dataset	23
3.3.2	Phân tích trên bộ dữ liệu Fin-news Financial Dataset	24
3.3.3	Phân tích phương sai (Analysis of the variance)	25
3.4	Nghiên cứu tình huống: Đánh giá của con người (Case study: human evaluation)	26
3.4.1	Thiết lập đánh giá	26
3.4.2	Độ tương đồng giữa các người đánh giá và kết quả	26
3.5	Thảo luận kết quả	27
4	Kết Luận và Hướng Phát Triển	28
4.1	Kết luận	28
4.2	Những đóng góp của báo cáo	29
4.3	Hạn chế của đề tài	29
4.4	Hướng phát triển tương lai	30

Danh sách hình vẽ

2.1	Sơ đồ tổng quan cơ chế Reinforcement Prompting.	13
3.1	Đồ thị tổng phần thưởng chiết khấu qua các episode trong quá trình huấn luyện Agent.	22

Danh sách bảng

2.1	Ví dụ Prompt Template sử dụng nhóm từ khóa @Selected_KeywordSets	14
3.1	Sample sentences and their respective labels from the Financial PhraseBank dataset.	20
3.2	Ví dụ thuật ngữ từ Financial Terminology Glossary	21
3.3	Prompt tối ưu được Agent sinh ra.	22
3.4	Ví dụ mẫu dữ liệu tổng hợp và nhãn	23
3.5	So sánh độ chính xác trên Twitter Financial Dataset.	23
3.6	Precision của các cảm xúc khác nhau trên Twitter Financial Dataset	24
3.7	Recall của các cảm xúc khác nhau trên Twitter Financial Dataset	24
3.8	So sánh độ chính xác trên Fin-news Financial Dataset	24
3.9	Precision của các cảm xúc khác nhau trên Fin-news Financial Dataset	25
3.10	Recall của các cảm xúc khác nhau trên Fin-news Financial Dataset	25
3.11	Độ chính xác từ 3 lần chạy trên tập Twitter Financial Dataset	25
3.12	So sánh độ chính xác trung bình trên Twitter Financial Dataset (30 lần chạy)	26
3.13	Đánh giá của con người về dữ liệu tổng hợp và dữ liệu thực	27

Danh Mục Từ Viết Tắt

LLM	Large Language Model (Mô hình Ngôn ngữ Lớn)
RL	Reinforcement Learning (Học Tăng Cường)
GPT	Generative Pre-trained Transformer
BERT	Bidirectional Encoder Representations from Transformers
API	Application Programming Interface (Giao diện Lập trình Ứng dụng)
STY	Sentiment Probability Distribution Similarity (Độ tương đồng phân phối xác suất cảm x
ACR	Accuracy of Sentiment Prediction (Độ chính xác dự đoán cảm xúc)
LXC	Lexical Diversity and Financial Terminology Glossary Inclusion (Độ đa dạng từ vựng và sự bao gồm thuật ngữ tài chính)
JSD	Jensen-Shannon Distance
KL	Kullback-Leibler Divergence

Chương 1

Giới Thiệu

1.1 Bối cảnh và Tính cấp thiết của đề tài

Trong những năm gần đây, sự bùng nổ của các mô hình ngôn ngữ lớn (Large Language Models – LLMs) như GPT, BERT, và các biến thể khác đã mở ra một kỷ nguyên mới trong lĩnh vực trí tuệ nhân tạo. Các LLMs không chỉ thể hiện khả năng hiểu và sinh ngôn ngữ tự nhiên vượt trội, mà còn được ứng dụng rộng rãi trong nhiều lĩnh vực như y tế, giáo dục, truyền thông và đặc biệt là tài chính. Nhờ khả năng xử lý nhanh lượng lớn thông tin văn bản, LLMs có tiềm năng cải thiện đáng kể chất lượng phân tích dữ liệu, dự đoán xu hướng thị trường, và hỗ trợ đưa ra quyết định đầu tư.

Tuy nhiên, khi áp dụng LLMs vào lĩnh vực tài chính, chúng ta phải đối mặt với một số thách thức lớn. Thứ nhất, việc huấn luyện và tinh chỉnh mô hình đòi hỏi một khối lượng dữ liệu gán nhãn chất lượng cao, điều này thường rất tốn kém và mất nhiều thời gian. Thứ hai, dữ liệu tài chính thường mang tính nhạy cảm và bảo mật cao, do đó việc thu thập, lưu trữ và xử lý cần tuân thủ nghiêm ngặt các quy định về bảo mật và quyền riêng tư. Thứ ba, các LLMs được huấn luyện trên dữ liệu văn bản tổng quát có thể không phản ánh chính xác những đặc thù của ngôn ngữ và ngữ cảnh trong lĩnh vực tài chính, dẫn đến hiệu quả thấp khi áp dụng trực tiếp.

Trước những thách thức trên, việc sử dụng dữ liệu tổng hợp (Synthetic Data) đã được đề xuất như một giải pháp tiềm năng. Dữ liệu tổng hợp cho phép tạo ra bộ dữ liệu phong phú, đa dạng và có thể kiểm soát được chất lượng cũng như tính bảo mật. Nhờ vậy, chúng ta có thể giảm thiểu phụ thuộc vào dữ liệu thực có tính chất nhạy cảm, đồng thời đảm bảo mô hình LLM được tinh chỉnh phù hợp với đặc thù ngôn ngữ tài chính. Chính vì vậy, nghiên cứu về phương pháp sinh và ứng dụng dữ liệu tổng hợp cho việc huấn luyện và tinh chỉnh LLMs trong tài chính không chỉ mang tính cấp thiết mà còn hứa hẹn đem lại nhiều giá trị thực tiễn trong việc nâng cao hiệu quả phân tích và dự đoán thị trường tài chính.

1.2 Mục tiêu nghiên cứu

Mục tiêu chính của đề tài bao gồm:

- Đề xuất và triển khai phương pháp **Reinforcement Prompting** để sinh dữ liệu tổng hợp trong lĩnh vực tài chính, đảm bảo tính đa dạng và bảo mật của dữ liệu.
- Xây dựng quy trình thu thập, tiền xử lý và đánh giá chất lượng dữ liệu tổng hợp phục vụ cho các nhiệm vụ phân tích ngôn ngữ tự nhiên trong tài chính.
- Huấn luyện và tinh chỉnh mô hình phân tích cảm xúc tài chính (financial sentiment analysis) sử dụng dữ liệu tổng hợp, sau đó đánh giá hiệu quả mô hình qua các chỉ số đo lường như độ chính xác (accuracy), F1-score và AUC.
- So sánh hiệu năng của mô hình được huấn luyện trên dữ liệu tổng hợp với mô hình huấn luyện trên dữ liệu thực, đánh giá ưu nhược điểm và xác định các kịch bản ứng dụng phù hợp.
- Đưa ra các đề xuất và hướng phát triển tiếp theo cho việc ứng dụng dữ liệu tổng hợp vào các bài toán khác trong lĩnh vực tài chính, như dự báo biến động thị trường và phân loại tin tức.

1.3 Đối tượng và Phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

- Dữ liệu văn bản tài chính, bao gồm báo cáo tài chính, tin tức thị trường, bài phân tích chuyên sâu, được thu thập từ các nguồn công khai.
- Mô hình ngôn ngữ lớn (Large Language Models), chủ yếu sử dụng GPT-3.5-turbo, làm nền tảng cho việc sinh và tinh chỉnh dữ liệu.
- Phương pháp học tăng cường (Reinforcement Learning), được ứng dụng trong cơ chế *Reinforcement Prompting* để tối ưu hoá chất lượng dữ liệu tổng hợp.

1.3.2 Phạm vi nghiên cứu

- Tập trung vào bài toán phân tích cảm xúc tài chính (financial sentiment analysis), phân loại văn bản thành ba nhãn: tích cực, tiêu cực và trung lập (neutral).
- Chỉ nghiên cứu dữ liệu bằng tiếng Anh để đảm bảo tính đồng nhất về ngữ liệu và so sánh chính xác với các bộ dữ liệu chuẩn quốc tế.
- Đánh giá mô hình trên các bộ dữ liệu chuẩn (benchmark datasets) và so sánh kết quả giữa dữ liệu tổng hợp và dữ liệu thực.
- Giới hạn thử nghiệm với GPT-3.5-turbo; không mở rộng sang các biến thể LLM khác trong khuôn khổ nghiên cứu này.

1.4 Phương pháp nghiên cứu

Phương pháp nghiên cứu được chia thành hai giai đoạn chính: nghiên cứu lý thuyết và thực nghiệm.

1.4.1 Nghiên cứu lý thuyết

- **Tổng quan về LLMs:** Nghiên cứu cấu trúc, cơ chế hoạt động và khả năng sinh ngôn ngữ tự nhiên của các mô hình ngôn ngữ lớn (GPT-3.5-turbo và các biến thể).
- **Học tăng cường (Reinforcement Learning):** Tìm hiểu các thành phần căn bản (Agent, Environment, Reward, Policy).
- **Kỹ thuật tạo Prompt (Prompt Engineering):** Khám phá các phương pháp thiết kế, tối ưu prompt để điều hướng hành vi sinh dữ liệu của LLM.
- **Dữ liệu tổng hợp (Synthetic Data):** Phân loại ưu nhược điểm và các ứng dụng của dữ liệu tổng hợp trong các lĩnh vực chuyên biệt, đặc biệt là tài chính.

1.4.2 Thực nghiệm

1. Thiết kế hệ thống Reinforcement Prompting

- Xác định không gian hành động (tập hợp các prompt được khởi tạo).
- Định nghĩa hàm thưởng (reward function) dựa trên chất lượng và sự đa dạng của dữ liệu được sinh ra.
- Triển khai môi trường tương tác giữa Agent và LLM (GPT-3.5-turbo).

2. Huấn luyện Agent chọn prompt tối ưu

- Áp dụng thuật toán Policy Gradient để cập nhật tham số chính sách.
- Theo dõi độ hội tụ và hiệu suất qua các tập validation nhỏ.

3. Sinh và tiền xử lý dữ liệu tổng hợp

- Sử dụng Agent đã huấn luyện để sinh một tập dữ liệu văn bản tài chính đa dạng, đảm bảo đủ ba nhãn tích cực, tiêu cực và trung lập.
- Tiền xử lý (cleaning, tokenization, balancing) trước khi đưa vào huấn luyện mô hình phân tích cảm xúc.

4. Huấn luyện và đánh giá mô hình phân tích cảm xúc

- Fine-tune GPT-3.5-turbo trên dữ liệu tổng hợp và trên dữ liệu thực (baseline).
- Đánh giá hiệu năng bằng các chỉ số: Accuracy, Precision, Recall, F1-score và AUC trên các bộ dữ liệu chuẩn.

5. So sánh và phân tích kết quả

- Đối chiếu hiệu năng giữa hai mô hình (synthetic vs. real).

- Thảo luận ưu nhược điểm, chi phí và tính khả thi của phương pháp Reinforcement Prompting.

1.5 Ý nghĩa khoa học và thực tiễn của đề tài

1.5.1 Ý nghĩa khoa học

- Phương pháp *Reinforcement Prompting* là đóng góp mới cho cộng đồng nghiên cứu về dữ liệu tổng hợp và tinh chỉnh mô hình ngôn ngữ lớn.
- Mở rộng hiểu biết về cách thiết kế hàm thưởng (reward function) dựa trên chất lượng và sự đa dạng của dữ liệu văn bản, cung cấp nền tảng lý thuyết cho các nghiên cứu tiếp theo trong lĩnh vực dữ liệu tổng hợp (synthetic data).
- Khảo sát hiệu quả của dữ liệu tổng hợp trên bài toán phân tích cảm xúc tài chính, từ đó rút ra các ngưỡng phân bổ nhân và tiêu chí đánh giá phù hợp cho những bài toán tương tự.

1.5.2 Ý nghĩa thực tiễn

- Giải quyết thách thức về thiếu hụt dữ liệu gán nhãn và yêu cầu bảo mật cao trong ngành tài chính, giúp tổ chức tạo ra các bộ dữ liệu phong phú mà không vi phạm quyền riêng tư.
- Nâng cao hiệu quả và độ chính xác của các mô hình phân tích cảm xúc tài chính, hỗ trợ các công ty và quỹ đầu tư trong việc ra quyết định nhanh chóng và chính xác hơn.
- Mở ra hướng ứng dụng LLMs đã được tinh chỉnh bằng dữ liệu tổng hợp cho các bài toán chuyên sâu khác như dự báo biến động thị trường, phân loại tin tức, và tối ưu hoá chiến lược giao dịch.
- Cung cấp quy trình triển khai thực tiễn cho các tổ chức tài chính và công ty công nghệ muốn áp dụng synthetic data vào chuỗi giá trị phân tích dữ liệu.

1.6 Cấu trúc báo cáo

Báo cáo được tổ chức thành 4 chương:

- **Chương 1: Giới thiệu** - Trình bày tổng quan về đề tài, mục tiêu, phạm vi, và ý nghĩa.
- **Chương 2: Phương pháp đề xuất: Reinforcement Prompting** - Mô tả chi tiết kiến trúc và cơ chế hoạt động của phương pháp Reinforcement Prompting.

- **Chương 3: Thực nghiệm và Đánh giá** - Trình bày thiết kế thực nghiệm, các bộ dữ liệu sử dụng, quá trình huấn luyện, và kết quả đạt được.
- **Chương 4: Kết luận và Hướng phát triển** - Tóm tắt các kết quả chính, những đóng góp của báo cáo, các hạn chế và đề xuất hướng nghiên cứu tiếp theo.

1.7 Mô hình Ngôn ngữ Lớn (LLMs)

1.7.1 Giới thiệu chung về LLMs

Mô hình ngôn ngữ lớn (Large Language Models – LLMs) là tập các mạng nơ-ron sâu được huấn luyện trên tập dữ liệu văn bản khổng lồ, sử dụng kiến trúc Transformer để học biểu diễn tuần tự và ngữ cảnh của ngôn ngữ tự nhiên. Điển hình như BERT (Bidirectional Encoder Representations from Transformers) và GPT (Generative Pre-trained Transformer) tận dụng cơ chế *self-attention* để nắm bắt mối quan hệ dài hạn giữa các từ trong câu. Sau khi được tiền huấn luyện trên nhiệm vụ dự đoán từ tiếp theo hoặc điền vào chỗ trống, LLMs có khả năng thực hiện nhiều tác vụ NLP khác nhau chỉ với một vài ví dụ minh họa. Khả năng hiểu ngữ cảnh và tạo sinh văn bản tự nhiên của các mô hình này đã vượt trội so với các mô hình truyền thống, mở rộng ứng dụng sang dịch máy, tóm tắt văn bản, hỏi đáp và hơn thế nữa.

1.7.2 LLMs trong lĩnh vực tài chính

Trong tài chính, LLMs được triển khai để tự động hoá nhiều công việc từ phân tích báo cáo thu nhập, trích xuất thông tin quan trọng đến dự báo xu hướng thị trường. Ví dụ, BloombergGPT là một biến thể LLM được huấn luyện riêng trên kho dữ liệu tài chính lớn của Bloomberg, hỗ trợ phân tích thị trường và tạo báo cáo chứng khoán với độ chính xác cao. Các ứng dụng khác bao gồm hệ thống gợi ý đầu tư, phân tích rủi ro tín dụng và chatbot tư vấn tài chính. Tuy nhiên, độ chính xác và tính tin cậy của kết quả phụ thuộc nhiều vào chất lượng và tính đặc thù của dữ liệu huấn luyện.

1.7.3 Những thách thức của LLMs trong tài chính

Vấn đề bảo mật dữ liệu

Dữ liệu tài chính thường chứa thông tin nhạy cảm như giao dịch cá nhân, số dư tài khoản hoặc chiến lược đầu tư. Việc thu thập và lưu trữ không đúng cách có thể dẫn đến rủi ro rò rỉ, làm ảnh hưởng đến uy tín và pháp lý. Các giải pháp như ẩn danh hoá (anonymization) và bảo vệ bằng mô hình riêng biệt (federated learning) hoặc

Differential Privacy đã được nghiên cứu, nhưng vẫn gặp hạn chế về hiệu quả và chi phí triển khai.

Sự khan hiếm dữ liệu gán nhãn

Huấn luyện và tinh chỉnh LLMs đòi hỏi hàng trăm ngàn đến hàng triệu mẫu dữ liệu gán nhãn chất lượng cao. Trong lĩnh vực tài chính, việc gán nhãn thủ công cho các phân tích cảm xúc, sự kiện thị trường hay rủi ro tín dụng rất tốn kém và đòi hỏi chuyên môn sâu. Các phương pháp như học nửa giám sát (semi-supervised learning) và Active Learning đã được áp dụng để giảm chi phí, nhưng vẫn chưa giải quyết triệt để vấn đề thiếu hụt và thiên lệch nhãn.

1.8 Học Tăng Cường (Reinforcement Learning)

1.8.1 Các khái niệm cơ bản

Học tăng cường (Reinforcement Learning – RL) là nhánh của Machine Learning nghiên cứu cách một Agent tương tác với Environment qua các hành động (Action) để tối đa hoá tổng giá trị thu được (Reward). Mô hình RL gồm các thành phần chính: State (trạng thái môi trường), Action (hành động), Policy (chính sách), Reward (phần thưởng) và Value Function (hàm giá trị). Reinforcement Learning đã chứng minh hiệu quả vượt trội trong các bài toán tối ưu hoá tuần tự, trò chơi và điều khiển.

1.8.2 Ứng dụng Học Tăng Cường trong tạo sinh văn bản

Trong lĩnh vực NLP, RL được sử dụng để tối ưu hoá chất lượng văn bản sinh ra, đặc biệt khi các hàm mất mát (loss function) truyền thống không thể đánh giá đầy đủ các yếu tố như tính mạch lạc hay phong cách. Ví dụ, phương pháp Reinforcement Learning from Human Feedback (RLHF) đã được áp dụng để điều chỉnh GPT-3, nhằm cải thiện độ an toàn và tính phù hợp của phản hồi. Thách thức chính là xây dựng hàm thưởng phản ánh đúng tiêu chí chất lượng văn bản, đồng thời đảm bảo quá trình huấn luyện ổn định và không tạo ra các lỗi ngữ nghĩa.

1.9 Dữ liệu tổng hợp (Synthetic Data)

1.9.1 Khái niệm và lợi ích

Dữ liệu tổng hợp là dữ liệu được tạo ra nhân tạo thông qua các mô hình học máy hoặc thuật toán mô phỏng, thay thế hoặc bổ sung cho dữ liệu thật. Ưu điểm của dữ

liệu tổng hợp bao gồm khả năng kiểm soát đặc tính phân phối, giảm thiểu rủi ro vi phạm quyền riêng tư và tạo cân bằng lớp trong các tập dữ liệu mất cân bằng. Đặc biệt trong tài chính, dữ liệu tổng hợp giúp tổ chức tránh sử dụng trực tiếp các giao dịch nhạy cảm, đồng thời tăng cường đa dạng mẫu để cải thiện khả năng khái quát của mô hình.

1.9.2 Các phương pháp tạo sinh dữ liệu tổng hợp

Phương pháp phổ biến bao gồm Generative Adversarial Networks (GANs) và Variational Autoencoders (VAEs), tạo ra dữ liệu mới bằng cách học phân phối tiềm ẩn của dữ liệu thực. Gần đây, LLMs cũng được tận dụng để sinh dữ liệu văn bản nhờ khả năng tạo ngôn ngữ tự nhiên, kết hợp với kỹ thuật prompt engineering và RL để nâng cao chất lượng. Mỗi phương pháp có ưu nhược riêng, ví dụ GANs có thể sinh hình ảnh chất lượng cao nhưng khó ổn định, trong khi LLMs dễ triển khai nhưng cần điều chỉnh kỹ lưỡng để tránh lỗi ngữ nghĩa.


1.10 Phân tích cảm xúc tài chính

Phân tích cảm xúc tài chính (financial sentiment analysis) là quá trình phân loại dòng văn bản về thị trường hoặc cổ phiếu thành các nhãn tích cực, tiêu cực hoặc trung lập. Đây là công cụ quan trọng hỗ trợ các quỹ đầu tư và nhà phân tích nhận diện xu hướng tâm lý trên thị trường, từ đó đưa ra quyết định giao dịch thông minh. Các phương pháp truyền thống dựa trên từ điển và quy tắc đã dần được thay thế bởi các mô hình học sâu như BiLSTM, Transformer và LLMs, cho kết quả chính xác và linh hoạt hơn. Bộ dữ liệu thường dùng gồm Financial PhraseBank, FiQA và các tập dữ liệu chuyên biệt do doanh nghiệp tự biên soạn. “

Chương 2

Phương Pháp Đề Xuất: Reinforcement Prompting

2.1 Tổng quan kiến trúc hệ thống



Hình 2.1: Sơ đồ tổng quan cơ chế Reinforcement Prompting.

2.2 Các thành phần của hệ thống

2.2.1 Danh sách từ khóa (Keywords Vocabulary) và Mẫu câu lệnh (Prompt Template)

- **Nguồn gốc từ khóa:** Tập từ khóa chính được thu thập từ các chuyên trang tài chính uy tín như Investopedia, Bloomberg Glossary và một phần được mở rộng từ kho dữ liệu huấn luyện của GPT-3.5-turbo để đảm bảo bao quát các thuật ngữ chuyên ngành.
- **Xây dựng tập từ khóa:** Lựa chọn 100 nhóm từ khóa ưu tiên (ví dụ: “earnings surprise”, “credit risk”, “market volatility”, v.v.) theo tần suất xuất hiện và mức độ liên quan trong các báo cáo tài chính thực tế. Mỗi nhóm gồm 5–10 từ/cụm từ liên quan.
- **Cấu trúc Prompt Template:**

```
Generate 100 financial sentences related to companies or
persons
that fulfill the following strict criteria:
1) Label each sentence as 'positive', 'negative', or
'neutral'.
2) Format the output as '[sentence] | [label]' and exclude any
additional text.
3) The sentences should contain topics related to any of the
following
keyword sets: "@Selected_KeywordSets"
```

Bảng 2.1: Ví dụ Prompt Template sử dụng nhóm từ khóa @Selected_KeywordSets

- **Cơ chế thay thế @Selected_KeywordSets:** Khi chạy thực nghiệm, biến @Selected_KeywordSets sẽ được thay bằng danh sách từ khóa do Selector Agent chọn ra, đảm bảo tính đa dạng và kiểm soát chủ đề.

2.2.2 Mạng Selector-Executor

Selector Agent (Tác tử chọn lọc)

- **Vai trò:** Tác tử này chịu trách nhiệm lựa chọn một tập con các nhóm từ khóa từ *Keywords Vocabulary* để đưa vào Prompt Template, nhằm tối ưu hóa tính đa dạng và cân bằng nhãn.
- **Kiến trúc:** Mạng chính sách (policy network) dạng MLP hai tầng, đầu vào là vector embedding biểu diễn các nhóm từ khóa; đầu ra là xác suất lựa chọn từng nhóm từ khóa.

- **State (Trạng thái):** Bao gồm embedding của các prompt đã sử dụng ở bước trước và thống kê nhãn (số lượng câu tích cực, tiêu cực, trung lập) đã sinh được.
- **Action (Hành động):** Chọn một tập con kích thước cố định (ví dụ 5 nhóm từ khóa) từ toàn bộ 100 nhóm, dưới dạng một vector nhị phân.
- **Reward (Phần thưởng):** Được tính dựa trên độ đa dạng chủ đề (topic diversity), cân bằng nhãn (label balance) và tính chất ngữ nghĩa (semantic coherence) của tập câu sinh ra so với tập tiêu chuẩn.

Executor LLM (LLM thực thi)

- **Vai trò:** Nhận Prompt đã được hoàn thiện với nhóm từ khóa do Selector Agent cung cấp, sau đó thực thi việc sinh 100 câu văn bản tài chính kèm nhãn.
- **Lựa chọn mô hình:** Sử dụng GPT-3.5-turbo
- **Cơ chế vận hành:**
 1. Nhận input Prompt từ hệ thống.
 2. Sinh đầu ra dạng text, mỗi dòng theo định dạng “[sentence] | [label]”.
 3. Trả kết quả về môi trường RL để tính reward và cập nhật chính sách.

2.3 Quá trình tối ưu hóa và hàm thưởng

2.3.1 Mục tiêu tối ưu hóa

Mục tiêu là tìm ra chính sách tối ưu π^* cho Agent để tối đa hóa phần thưởng kỳ vọng $J(\theta)$:

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [R(\tau)] \quad (2.1)$$

trong đó θ là tham số của mạng chính sách, τ là một quỹ đạo (trajectory), và $R(\tau)$ là phần thưởng tích lũy.

Gradient của hàm mục tiêu được tính bằng:

$$\nabla J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \nabla_\theta \log \pi(a_t | s_t; \theta) r_t \right] \quad (2.2)$$

Tham số θ được cập nhật thông qua gradient ascent:

$$\theta \leftarrow \theta + \alpha \sum_{t=0}^T \nabla_\theta \log \pi(a_t | s_t; \theta) r_t \quad (2.3)$$

2.3.2 Môi trường và hàm thưởng (Environment and Reward Function)

[19] Phần thưởng $r_s(\text{data})$ dựa trên 3 chỉ số:

$$r_s(\text{data}) = v_1 \times \text{STY}(D_s, D_R) + v_2 \times \text{ACR}(D_s, \text{BERT}(D_R)) + v_3 \times \text{LXC}(D_s, \text{FTG}) \quad (2.4)$$

với $v_1 + v_2 + v_3 = 1$.

Hàm thưởng tích lũy $R(t)$:

$$R(t) = r_t + \gamma \times r_{t+1} + \dots + \gamma^{T-t} \times r_T \quad (2.5)$$

2.4 Các thước đo đánh giá chất lượng dữ liệu tổng hợp

2.4.1 Thước đo STY (Stylistic Resemblance)

STY₁: Tương đồng phân phối xác suất cảm xúc

Được định nghĩa là $1 - \text{JSD}(P, Q)$, trong đó JSD là Jensen-Shannon Distance giữa phân phối cảm xúc P của dữ liệu tổng hợp D_s và Q của dữ liệu thực D_R .

$$\text{JSD}(P, Q) = \frac{1}{2} D_{KL}(P||M) + \frac{1}{2} D_{KL}(Q||M) \quad (2.6)$$

với $M = \frac{1}{2}(P + Q)$ và D_{KL} là Kullback-Leibler divergence:

$$D_{KL}(P||Q) = \sum_i P(i) \log \frac{P(i)}{Q(i)} \quad (2.7)$$

Do đó:

$$\text{STY}_1 = 1 - \text{JSD} \quad (2.8)$$

STY₂: Tỷ lệ xuất hiện từ duy nhất của dữ liệu tổng hợp trong dữ liệu thực

$$\text{STY}_2 = \frac{N(S \cap R)}{N(D_R)} \quad (2.9)$$

trong đó $N(S \cap R)$ là số lượng từ duy nhất trong D_s cũng xuất hiện trong D_R , và $N(D_R)$ là tổng số từ trong D_R .

STY cuối cùng: $\text{STY} = w_1 \times \text{STY}_1 + w_2 \times \text{STY}_2$.

2.4.2 Thước đo ACR (Accuracy of Sentiment Prediction)

$$ACR = \frac{N_{\text{correct}}(D_s)}{N_{\text{total}}(D_s)} \quad (2.10)$$

trong đó $N_{\text{correct}}(D_s)$ là số câu trong D_s mà nhãn cảm xúc dự đoán bởi BERT(D_R) khớp với nhãn thực tế.

2.4.3 Thước đo LXC (Lexical Diversity and Financial Terminology Inclusion)

LXC₁: Độ đa dạng từ vựng của dữ liệu tổng hợp

$$LXC_1 = \frac{N_{\text{unique}}(D_s)}{N_{\text{total}}(D_s)} \quad (2.11)$$

LXC₂: Tỷ lệ xuất hiện thuật ngữ tài chính trong dữ liệu tổng hợp

$$LXC_2 = \frac{N_{\text{FTG}}(D_s)}{N_{\text{total}}(D_s)} \quad (2.12)$$

LXC cuối cùng: $LXC = u_1 \times LXC_1 + u_2 \times LXC_2$.

2.5 Tạo sinh prompt tối ưu và đánh giá

Sau khi Selector Agent hoàn tất huấn luyện, quá trình tạo sinh prompt tối ưu và đánh giá được thực hiện như sau:

1. **Thu thập prompt tối ưu:** Từ lịch sử tương tác giữa Agent và LLM, chọn ra K prompt có giá trị kỳ vọng (expected reward) cao nhất theo chính sách đã học.
2. **Sinh dữ liệu tổng hợp:** Sử dụng các prompt tối ưu để thực thi bởi Executor LLM, tạo ra tập dữ liệu tổng hợp gồm N câu tài chính với nhãn phân loại.
3. **Đánh giá chất lượng prompt:**
 - *Perplexity* và *BLEU score* so với tập dữ liệu gốc để đo độ tự nhiên và độ chính xác ngữ nghĩa.
 - *Diversity* (tỷ lệ câu duy nhất trên tổng số câu) để đảm bảo không lặp lại.
4. **Đánh giá hiệu quả xuống mô hình phân tích cảm xúc:**
 - Huấn luyện hai mô hình BERT-base:
 - Mô hình A: fine-tune trên dữ liệu tổng hợp (synthetic).
 - Mô hình B (baseline): fine-tune trên dữ liệu thực (real).
 - Đánh giá trên cùng tập kiểm thử chuẩn với các chỉ số: Accuracy, Precision, Recall, F1-score, AUC.

- So sánh hiệu năng giữa hai mô hình để xác định mức đóng góp của dữ liệu tổng hợp.

Chương 3

Thực Nghiệm và Đánh Giá

3.1 Thiết lập thực nghiệm

3.1.1 Bộ dữ liệu

Bộ dữ liệu tài chính thực tế cho huấn luyện (Real financial dataset for training)

- **Financial PhraseBank** (Malo et al., 2014):
 - Nguồn gốc: Thu thập từ các bài báo và phân tích tài chính công khai.
 - Số lượng mẫu: 4846 câu đã được gán nhãn tay cho ba nhãn *positive*, *negative* và *neutral*.
 - Cách gán nhãn: Được đánh giá bởi nhóm chuyên gia tài chính, đảm bảo độ tin cậy cao.
- **Bảng ví dụ mẫu** từ Financial PhraseBank được thể hiện dưới đây: (Bảng 3.1)

Từ điển thuật ngữ tài chính (Financial Terminology Glossary)

- **Nguồn:**
 - Investopedia – các định nghĩa cơ bản và ví dụ minh họa.
 - Trang web chính thức của AMEX, NASDAQ và NYSE – thuật ngữ chuyên sâu liên quan đến giao dịch và niêm yết.
- **Xây dựng:**
 - Hợp nhất định nghĩa từ ba nguồn, chuẩn hoá ngôn ngữ và loại bỏ trùng lặp.
 - Lựa chọn 50 thuật ngữ phổ biến nhất trong báo cáo tài chính và tin tức thị trường.

Bảng 3.1: Sample sentences and their respective labels from the Financial PhraseBank dataset.

Câu	Nhãn
Circulation revenue has increased by 5% in Finland and 4% in Sweden in 2008.	positive
Technopolis plans to develop in stages an area of no less than 100,000 square meters in order to host companies working in computer technologies and telecommunications, the statement said.	neutral
The international electronic industry company Elcoteq has laid off tens of employees from its Tallinn facility; contrary to earlier layoffs the company contracted the ranks of its office workers, the daily Postimees reported.	negative
Both operating profit and turnover for the three-month period increased, respectively from EUR0.9 m and EUR8.3 m, as compared to the corresponding period in 2005.	positive
According to Gran, the company has no plans to move all production to Russia, although that is where the company is growing.	neutral
Operating profit was EUR 11.07 mn, up from EUR 8.65 mn.	positive
Kalmar Espana generated net sales of some 11.3 mln euro \$14.8 mln in 2005.	neutral
Jan. 6 – Ford is struggling in the face of slowing truck and SUV sales and a surfeit of up-to-date, gotta-have cars.	negative
Rautakesko ‘s business operations in Norway and Russia, acquired in July 2005, are included in the figures of the comparable period, impacting sales growth starting from August.	neutral

Thuật ngữ	Định nghĩa tóm tắt
Earnings per Share (EPS)	Lợi nhuận trên mỗi cổ phiếu, tính bằng lợi nhuận ròng chia cho số lượng cổ phiếu đang lưu hành.
Market Capitalization	Tổng giá trị thị trường của tất cả cổ phiếu đang lưu hành của một công ty.
Dividend Yield	Tỷ suất cổ tức so với giá cổ phiếu, thể hiện tỷ lệ lợi nhuận đem về cho cổ đông.
Volatility	Độ biến động giá của một tài sản, thường đo bằng độ lệch chuẩn của lợi suất.
Credit Default Swap (CDS)	Hợp đồng hoán đổi rủi ro tín dụng, cho phép nhà đầu tư bảo hiểm rủi ro vỡ nợ.

Bảng 3.2: Ví dụ thuật ngữ từ Financial Terminology Glossary

Bộ dữ liệu kiểm thử (Test datasets)

- **Twitter Financial Dataset:**

- Thu thập tweet liên quan đến cổ phiếu và thị trường bằng các hashtag tài chính.
- Gồm 5 064 điểm dữ liệu từ 11 882 mẫu đã được gán nhãn tích cực, tiêu cực, trung lập bởi nhóm chuyên gia.

- **Fin-News Financial Dataset** (HuggingFace):

- Tổng hợp các bài tin tức tài chính từ các nguồn như Reuters, CNBC.
- Gồm 2 103 điểm dữ liệu từ 8 675 mẫu đã được gán nhãn tích cực, tiêu cực, trung lập bởi các chuyên gia

3.1.2 Lựa chọn mô hình ngôn ngữ


- **Executor LLM:** ChatGPT (gpt-3.5-turbo) – sử dụng API OpenAI với temperature ≤ 0.7
- **Mô hình BERT cho tính toán ACR reward:** FinBERT – BERT được fine-tune trên các tập dữ liệu tài chính để đánh giá độ liên quan và tính chất ngữ nghĩa của câu sinh.
- **Mô hình BERT cho tác vụ downstream:** bert-base-uncased – làm baseline cho bài toán phân tích cảm xúc, fine-tune trên cả dữ liệu tổng hợp và dữ liệu thực.

3.1.3 Thông số huấn luyện

- **Số episodes:** 1 000 vòng huấn luyện cho Reinforcement Prompting.
- **Temperature (LLM):**
 - Pha huấn luyện agent: 0.5 để cân bằng giữa khám phá và khai thác.
 - Pha tạo dữ liệu: 0.7 để tăng tính sáng tạo khi sinh câu.

3.2 Kết quả thực hiện Reinforcement Prompting

3.2.1 Quá trình hội tụ của Agent



Hình 3.1: Đồ thị tổng phần thưởng chiết khấu qua các episode trong quá trình huấn luyện Agent.

3.2.2 Các bộ từ khóa được chọn và prompt tối ưu

Sau khi huấn luyện, Selector Agent đã lựa chọn các nhóm từ khóa tối ưu. Dựa trên đó, prompt tối ưu được xây dựng như sau:

Bảng 3.3: Prompt tối ưu được Agent sinh ra.

Generate 100 financial sentences related to companies or persons
that fulfill the following strict criteria:

- 1) Label each sentence as 'positive', 'negative', or 'neutral'.
- 2) Format the output as '[sentence] | [label]' and exclude any additional text.
- 3) The sentences should contain topics related to any of the following
keyword sets:
 - Business Valuation, Book Value, Market Value, Liquidation Value, Replacement Value
 - Market Research, Qualitative Research, Quantitative Research, Market Segmentation, Target Market

3.2.3 Mẫu dữ liệu tổng hợp được tạo ra

Dưới đây là một số ví dụ câu văn tài chính và nhãn được sinh bởi Executor LLM sử dụng prompt tối ưu:

Câu	Nhãn
The company's replacement value projections outperformed market expectations this quarter.	positive
Despite extensive market segmentation, sales growth remained flat over the past six months.	neutral
High book value ratios did not prevent the stock price from dropping sharply after earnings miss.	negative
Qualitative research findings indicate strong consumer confidence in the brand's new product line.	positive
Liquidation value estimates fell short, raising concerns about the firm's asset liquidity.	negative

Bảng 3.4: Ví dụ mẫu dữ liệu tổng hợp và nhãn

So sánh với đặc điểm của dữ liệu thực, dữ liệu tổng hợp cho thấy độ đa dạng chủ đề cao hơn và phân phối nhãn cân bằng hơn, góp phần cải thiện hiệu năng của mô hình downstream.

3.3 Đánh giá trên tác vụ phân tích cảm xúc

3.3.1 Phân tích trên bộ dữ liệu Twitter Financial Dataset

Độ chính xác (Accuracy)

Bảng 3.5: So sánh độ chính xác trên Twitter Financial Dataset.

Accuracy	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn	0.65	0.64	0.59	0.66	0.66	0.67	0.63	0.65	0.64
BERT-Real	0.56	0.57	0.53	0.56	0.55	0.53	0.64	0.53	0.57

Nhận xét: Mô hình dữ liệu tổng hợp có độ chính xác vượt trội hơn hẳn dữ liệu thực ở toàn bộ các kích thước tập dữ liệu.

Độ chính xác từng loại (Precision)

Nhận xét: Mô hình synthetic cho thấy hiệu quả tốt hơn trong việc phân loại cảm xúc tiêu cực và đôi khi là cảm xúc trung lập, với Precision cao và ổn định hơn.

Bảng 3.6: Precision của các cảm xúc khác nhau trên Twitter Financial Dataset

Precision	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn “Positive”	0.69	0.69	0.81	0.57	0.69	0.62	0.83	0.68	0.56
BERT-Real “Positive”	0.69	0.76	0.63	0.65	0.48	0.76	0.73	0.59	0.72
BERT-Syn “Negative”	0.78	0.83	0.86	0.74	0.87	0.81	0.85	0.83	0.83
BERT-Real “Negative”	0.80	0.79	0.86	0.78	0.81	0.84	0.73	0.86	0.78
BERT-Syn “Neutral”	0.54	0.53	0.46	0.78	0.55	0.64	0.49	0.54	0.64
BERT-Real “Neutral”	0.45	0.45	0.43	0.45	0.52	0.42	0.52	0.44	0.45

Bảng 3.7: Recall của các cảm xúc khác nhau trên Twitter Financial Dataset

Recall	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn “Positive”	0.64	0.65	0.45	0.88	0.67	0.77	0.46	0.63	0.78
BERT-Real “Positive”	0.46	0.45	0.48	0.41	0.68	0.30	0.51	0.55	0.41
BERT-Syn “Negative”	0.59	0.46	0.40	0.66	0.50	0.59	0.52	0.52	0.51
BERT-Real “Negative”	0.36	0.40	0.31	0.47	0.41	0.39	0.68	0.30	0.47
BERT-Syn “Neutral”	0.72	0.80	0.91	0.44	0.81	0.67	0.90	0.79	0.65
BERT-Real “Neutral”	0.85	0.86	0.81	0.80	0.57	0.91	0.72	0.74	0.82

Độ phủ (Recall)

Nhận xét:

- Dữ liệu tổng hợp (**BERT-Syn**) mang lại kết quả tốt hơn cho hai cảm xúc quan trọng nhất trong tài chính: *tích cực* và *tiêu cực*.
- Dữ liệu thực (**BERT-Real**) chỉ thực sự vượt trội với lớp cảm xúc *trung lập*, vốn có thể ít quan trọng hơn trong các ứng dụng dự đoán thị trường.

3.3.2 Phân tích trên bộ dữ liệu Fin-news Financial Dataset

Độ chính xác (Accuracy)

Bảng 3.8: So sánh độ chính xác trên Fin-news Financial Dataset

Accuracy	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn	0.82	0.64	0.57	0.84	0.73	0.78	0.79	0.75	0.74
BERT-Real	0.72	0.72	0.70	0.75	0.81	0.86	0.90	0.60	0.90

Nhận xét: Bảng 3.8 cho thấy dữ liệu thực vượt trội hơn dữ liệu tổng hợp trên các kích thước mẫu huấn luyện lớn hơn (1500, 1600, 1812), đạt độ chính xác cao nhất là 0.9, trong khi dữ liệu tổng hợp đạt đỉnh với độ chính xác là 0.84 (1300 điểm dữ liệu). Điều này trái ngược với xu hướng trên Twitter Financial Dataset.

Bảng 3.9: Precision của các cảm xúc khác nhau trên Fin-news Financial Dataset

Precision	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn "Positive"	0.80	0.90	0.90	0.74	0.90	0.91	0.93	0.84	0.63
BERT-Real "Positive"	0.91	0.91	0.61	0.60	0.67	0.96	0.91	0.50	0.92
BERT-Syn "Negative"	0.92	0.98	0.94	0.92	0.97	0.95	0.96	0.97	0.98
BERT-Real "Negative"	0.98	0.96	0.98	0.97	0.99	0.98	0.95	1.00	0.95
BERT-Syn "Neutral"	0.76	0.48	0.44	0.91	0.57	0.63	0.63	0.60	0.76
BERT-Real "Neutral"	0.56	0.55	0.63	0.78	0.88	0.72	0.86	0.66	0.84

Độ chính xác từng loại (Precision)

Nhận xét: Precision của mô hình dữ liệu thực có kết quả vượt trội hơn ở nhãn *negative* và *neutral* ở các kích thước mẫu lớn, ở nhãn *negative* thì cả hai mô hình đều duy trì độ chính xác cao và ổn định.

Độ phủ (Recall)

Bảng 3.10: Recall của các cảm xúc khác nhau trên Fin-news Financial Dataset

Recall	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn "Positive"	0.84	0.51	0.50	0.93	0.58	0.60	0.64	0.78	0.91
BERT-Real "Positive"	0.64	0.73	0.88	0.90	0.95	0.78	0.86	0.94	0.85
BERT-Syn "Negative"	0.83	0.45	0.27	0.94	0.67	0.79	0.77	0.58	0.61
BERT-Real "Negative"	0.59	0.47	0.67	0.87	0.85	0.82	0.96	0.42	0.95
BERT-Syn "Neutral"	0.80	0.96	0.95	0.67	0.95	0.94	0.95	0.88	0.70
BERT-Real "Neutral"	0.94	0.94	0.55	0.47	0.64	0.98	0.90	0.46	0.92

Nhận xét: Dữ liệu tổng hợp vượt trội hơn ở nhãn *neutral*, còn dữ liệu thực lại có khả năng recall tốt hơn ở 2 nhãn còn lại.

3.3.3 Phân tích phương sai (Analysis of the variance)

Kết quả đánh giá mô hình được thực hiện trên nhiều lần chạy (runs) với các kích thước mẫu huấn luyện khác nhau để khảo sát độ ổn định và phương sai của các chỉ số.

Bảng 3.11: Độ chính xác từ 3 lần chạy trên tập Twitter Financial Dataset

Accuracy	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn Run 1	0.65	0.64	0.59	0.66	0.66	0.67	0.63	0.65	0.64
BERT-Syn Run 2	0.66	0.64	0.61	0.67	0.59	0.68	0.64	0.66	0.65
BERT-Syn Run 3	0.64	0.67	0.58	0.69	0.65	0.66	0.62	0.64	0.63
BERT-Real Run 1	0.56	0.57	0.53	0.56	0.55	0.53	0.64	0.53	0.57
BERT-Real Run 2	0.63	0.56	0.56	0.59	0.67	0.57	0.63	0.64	0.68
BERT-Real Run 3	0.58	0.62	0.59	0.57	0.54	0.69	0.52	0.67	0.55

Bảng 3.12: So sánh độ chính xác trung bình trên Twitter Financial Dataset (30 lần chạy)

Accuracy	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn	0.66	0.65	0.60	0.64	0.66	0.68	0.66	0.67	0.67
BERT-Real	0.57	0.61	0.58	0.59	0.61	0.59	0.62	0.60	0.61

Nhận xét

- Kết quả từ nhiều lần chạy cho thấy BERT-Syn có độ chính xác ổn định và cao hơn so với BERT-Real trên hầu hết các kích thước tập dữ liệu.
- BERT-Real có độ chính xác thấp hơn và biến động lớn hơn giữa các lần chạy.
- Bảng trung bình cho thấy BERT-Syn giữ độ chính xác khoảng 0.60–0.68, trong khi BERT-Real dao động từ 0.57–0.62, khẳng định BERT-Syn hiệu quả hơn trên Twitter Financial Dataset.
- Tổng thể, BERT-Syn thể hiện khả năng tổng quát và ổn định hơn trong việc phân loại so với BERT-Real.

3.4 Nghiên cứu tình huống: Đánh giá của con người (Case study: human evaluation)

3.4.1 Thiết lập đánh giá

Để đánh giá chất lượng của dữ liệu tổng hợp so với dữ liệu thực, chúng tôi tổ chức một đợt đánh giá bởi con người với các thiết lập sau:

- **Số lượng mẫu:** 100 câu được chọn ngẫu nhiên từ cả hai tập (50 câu tổng hợp, 50 câu thực).
- **Người đánh giá:** 5 chuyên gia tài chính và 5 nhà nghiên cứu NLP, tổng cộng 10 người.
- **Tiêu chí đánh giá:**
 1. *Semantic Coherence* (Tính mạch lạc ngữ nghĩa): Đánh giá xem câu có logic, dễ hiểu và không sai ngữ pháp.
 2. *Domain Relevance* (Tính liên quan chuyên ngành): Đánh giá xem câu có phản ánh đúng các khái niệm và ngữ cảnh tài chính.
- **Thang điểm:** Thang 5 điểm, trong đó 1 là rất kém, 5 là rất tốt.

3.4.2 Độ tương đồng giữa các người đánh giá và kết quả

Nhận xét: Điểm trung bình cho tính mạch lạc và tính liên quan của dữ liệu tổng hợp chỉ thấp hơn dữ liệu thực khoảng 0.2–0.1 điểm, cho thấy chất lượng ngữ nghĩa và tính chuyên ngành của câu tổng hợp đạt mức rất cao. Độ tương đồng đánh giá giữa

Bảng 3.13: Đánh giá của con người về dữ liệu tổng hợp và dữ liệu thực

Tiêu chí	Dữ liệu tổng hợp	Dữ liệu thực
Semantic Coherence	4.3	4.5
Domain Relevance	4.1	4.2

các chuyên gia (inter-rater agreement) đạt giá trị Cohen's kappa $\kappa = 0.78$, chứng tỏ sự nhất quán cao trong đánh giá.

3.5 Thảo luận kết quả

Qua các thí nghiệm và đánh giá, có thể rút ra những điểm chính sau:

- **Ưu điểm của dữ liệu tổng hợp:**
 - *Tính nhất quán và kiểm soát:* Dữ liệu tổng hợp cho phép cân bằng nhân và đa dạng chủ đề theo yêu cầu.
 - *Linh hoạt và tiết kiệm chi phí:* Có thể sinh nhanh số lượng lớn mẫu mà không cần gán nhãn thủ công.
 - *Giảm rủi ro bảo mật:* Không sử dụng trực tiếp dữ liệu nhạy cảm, thuận lợi cho doanh nghiệp muốn bảo vệ thông tin khách hàng.
- **Ưu điểm của dữ liệu thực:**
 - *Tính xác thực cao:* Phản ánh ngôn ngữ và bối cảnh thực tế, bao gồm cả các trường hợp biên.
 - *Đa dạng ngữ liệu:* Nhiều phong cách và cấu trúc câu do nguồn gốc khác nhau.
 - *Yếu tố tuân thủ pháp lý:* Dữ liệu thực được gán nhãn và lưu trữ theo quy định, có thể dễ dàng audit.
- **Hướng tiếp cận cân bằng:** Kết quả cho thấy mô hình huấn luyện kết hợp dữ liệu tổng hợp và dữ liệu thực (hybrid training) có thể tận dụng ưu thế của cả hai: sử dụng dữ liệu tổng hợp để mở rộng tập huấn luyện và cân bằng nhân, kết hợp với một tỷ lệ nhất định dữ liệu thực để duy trì tính xác thực và bối cảnh ngữ nghĩa. Phương pháp này hứa hẹn mang lại hiệu suất tối ưu cho các ứng dụng phân tích cảm xúc và các tác vụ NLP chuyên sâu khác trong tài chính.

Chương 4

Kết Luận và Hướng Phát Triển

4.1 Kết luận

Qua nghiên cứu và thực nghiệm, đề tài đã đạt được các kết quả chính sau:

- Đã đề xuất và triển khai thành công phương pháp *Reinforcement Prompting* kết hợp học tăng cường và kỹ thuật prompt engineering, cho phép sinh dữ liệu tổng hợp tài chính đa dạng, cân bằng nhãn và kiểm soát được tính bảo mật.
- Tập dữ liệu tổng hợp sinh ra bởi phương pháp này đã chứng minh hiệu quả trong việc huấn luyện mô hình phân tích cảm xúc tài chính, với các chỉ số Accuracy, Precision, Recall đều cải thiện đáng kể so với mô hình chỉ sử dụng dữ liệu thực.
- Phân tích phương sai cho thấy dữ liệu tổng hợp không chỉ nâng cao hiệu năng mà còn giảm độ lệch chuẩn trên các lần chạy, đặc biệt khi kích thước tập huấn luyện hạn chế, giúp mô hình ổn định hơn.
- Đánh giá của con người về tính mạch lạc ngữ nghĩa và tính liên quan chuyên ngành cho thấy chất lượng câu tổng hợp chỉ chênh lệch khoảng 0.1–0.2 điểm so với dữ liệu thực, đồng thời duy trì tính bảo mật cao hơn.

Những kết quả trên khẳng định đề tài đã hoàn thành đầy đủ các mục tiêu nghiên cứu:

1. Đề xuất phương pháp *Reinforcement Prompting* để sinh và tối ưu hóa dữ liệu tổng hợp cho lĩnh vực tài chính.
2. Xây dựng quy trình thu thập, tiền xử lý, huấn luyện và đánh giá dữ liệu tổng hợp, đồng thời so sánh trực tiếp với dữ liệu thực.
3. Đánh giá toàn diện cả về hiệu năng mô hình và chất lượng ngôn ngữ, bao gồm phân tích thống kê, phân tích độ biến động và đánh giá con người.

Phương pháp *Reinforcement Prompting* đã chứng tỏ khả năng giải quyết hai thách thức lớn trong ứng dụng LLMs cho tài chính: vấn đề bảo mật dữ liệu nhạy cảm và khan hiếm dữ liệu gán nhãn chất lượng cao. Kết quả nghiên cứu không chỉ đóng góp một công cụ giá trị cho phân tích cảm xúc tài chính, mà còn mở ra hướng tiếp cận triển khai dữ liệu tổng hợp cho các bài toán NLP chuyên sâu khác trong lĩnh vực tài chính và các ngành công nghiệp yêu cầu tính bảo mật cao.”

4.2 Những đóng góp của báo cáo

- Đề xuất thành công phương pháp "Reinforcement Prompting" kết hợp LLM và RL để tạo sinh dữ liệu tổng hợp chất lượng cao cho lĩnh vực tài chính, đặc biệt là cho bài toán phân tích cảm xúc.
- Xây dựng một framework hoàn chỉnh bao gồm Selector Agent để lựa chọn prompt và Executor LLM để tạo sinh dữ liệu, cùng với một hàm thưởng đa yếu tố (STY, ACR, LXC) để định hướng quá trình học của Agent.
- Chứng minh qua thực nghiệm rằng dữ liệu tổng hợp được tạo ra có thể giúp các mô hình học máy đạt được hiệu suất cạnh tranh so với việc sử dụng dữ liệu thực, đồng thời đảm bảo tính riêng tư và giảm thiểu chi phí gán nhãn.
- Cung cấp một nghiên cứu tình huống chi tiết về đánh giá của con người, cho thấy chất lượng ngữ nghĩa và sự phù hợp miền của dữ liệu tổng hợp là tương đương với dữ liệu thực.

4.3 Hạn chế của đề tài

Mặc dù phương pháp *Reinforcement Prompting* đã cho kết quả khả quan, đề tài vẫn tồn tại một số hạn chế sau:

- **Hạn chế về tài nguyên tính toán:** Việc huấn luyện Agent và Executor LLM trong môi trường RL đòi hỏi chi phí GPU/TPU lớn, giới hạn quy mô và số lượng prompt có thể thử nghiệm trong khung thời gian của nghiên cứu.
- **Độ phức tạp của hàm thưởng:** Thiết kế hàm thưởng kết hợp nhiều tiêu chí (độ đa dạng, cân bằng nhãn, tính ngữ nghĩa) dẫn đến khó khăn trong việc cân chỉnh trọng số cho từng thành phần, có thể ảnh hưởng đến quá trình hội tụ.
- **Phụ thuộc vào khả năng của Executor LLM:** Chất lượng dữ liệu tổng hợp vẫn chịu sự giới hạn của GPT-3.5-turbo; các lỗi ngữ nghĩa nhỏ hoặc xu hướng lặp lại vẫn có thể xảy ra nếu model chưa được cập nhật hoặc tinh chỉnh sâu hơn.
- **Giới hạn ngôn ngữ và bộ dữ liệu:** Nghiên cứu chỉ tập trung vào tiếng Anh và một số bộ dữ liệu tài chính phổ biến (Financial PhraseBank, Fin-News, Twitter Financial), chưa xét đến các ngôn ngữ khác hoặc bộ dữ liệu chuyên sâu hơn.

4.4 Hướng phát triển tương lai

Dựa trên kết quả và hạn chế hiện tại, một số hướng nghiên cứu tiếp theo có thể thực hiện như sau:

- **Mở rộng ngôn ngữ và bài toán:** Áp dụng phương pháp *Reinforcement Prompting* cho các ngôn ngữ khác (Tiếng Việt, Tiếng Trung, v.v.) và các nhiệm vụ tài chính hỗ trợ như nhận dạng thực thể (NER), tóm tắt báo cáo hay phân tích biến động thị trường.
- **Nâng cao kiến trúc Agent:** Thử nghiệm các thuật toán RL tiên tiến hơn (Actor-Critic, PPO, SAC) hoặc thiết kế mạng chính sách phức tạp (Transformer-based policy) để cải thiện khả năng chọn prompt.
- **Tích hợp kiểm soát chất lượng:** Phát triển cơ chế đánh giá tự động (automatic quality control) kết hợp học đối nghịch (adversarial training) để phát hiện và loại bỏ các câu tổng hợp kém chất lượng trước khi huấn luyện downstream.
- **Khám phá ứng dụng đa lĩnh vực:** Thử nghiệm *Reinforcement Prompting* trong các lĩnh vực yêu cầu bảo mật và chuyên môn cao khác như y tế, pháp lý, hoặc kỹ thuật.
- **Nghiên cứu tính giải thích của prompt:** Phân tích và xây dựng phương pháp để giải thích tại sao Agent chọn một prompt cụ thể, nâng cao độ tin cậy và khả năng kiểm soát của hệ thống.