

Reinforcement Prompting Tạo Dữ liệu Tổng hợp trong Lĩnh vực Tài chính

Trần Quốc Khánh- 23020387
Hoàng Ngọc Nam - 23020403
Nguyễn Văn Linh - 23020395
Nguyễn Hữu Hoàng Nam - 23020405

Tóm tắt nội dung

Sự nổi lên của các Mô hình Ngôn ngữ Lớn đã mở ra tiềm năng chưa từng có trong việc hiểu và tạo ra văn bản giống như con người, thúc đẩy những tiến bộ trong lĩnh vực tài chính – một công cụ có thể định hình các chiến lược đầu tư và dự đoán thị trường. Tuy nhiên, những thách thức xuất phát từ nhu cầu về lượng lớn dữ liệu được gán nhãn và yêu cầu cấp thiết về bảo mật dữ liệu vẫn còn tồn tại. Việc tạo ra dữ liệu tổng hợp chất lượng cao nổi lên như một hướng đi đầy hứa hẹn để giải quyết những vấn đề này. Trong bài báo này, chúng tôi giới thiệu một phương pháp luận mới, được đặt tên là “Reinforcement Prompting”, để giải quyết những thách thức này. Chiến lược của chúng tôi sử dụng một mạng chính sách đóng vai trò là Bộ chọn để tạo ra các prompt, và một LLM đóng vai trò là Executor để sản xuất dữ liệu tài chính tổng hợp. Quá trình tạo dữ liệu tổng hợp này bảo vệ quyền riêng tư dữ liệu và giảm thiểu sự phụ thuộc vào các bộ dữ liệu thực tế được gán nhãn. Chúng tôi xác thực tính hiệu quả của phương pháp của mình thông qua các đánh giá thực nghiệm. Kết quả của chúng tôi chỉ ra rằng các mô hình được huấn luyện trên dữ liệu tổng hợp được tạo ra thông qua phương pháp của chúng tôi thể hiện hiệu suất cạnh tranh khi so sánh với các mô hình được huấn luyện trên dữ liệu tài chính thực tế, qua đó thu hẹp khoảng cách về hiệu suất. Nghiên cứu này cung cấp một giải pháp mới cho những thách thức về bảo mật dữ liệu và sự khan hiếm dữ liệu được gán nhãn trong phân tích cảm xúc tài chính, mang lại sự tiến bộ đáng kể trong lĩnh vực học máy tài chính.

Keywords: Reinforcement prompting; Reinforcement learning; Synthetic data; Large language model; Financial sentiment analysis; Machine learning.

1 Giới Thiệu

Các mô hình ngôn ngữ lớn (Large Language Models - LLMs) đã tạo ra một cuộc cách mạng trong việc xử lý và hiểu ngôn ngữ tự nhiên, mở ra những ứng dụng đột phá trong nhiều lĩnh vực, từ chăm sóc sức khỏe, giáo dục, dịch vụ khách hàng đến tài chính [14, 27]. Trong lĩnh vực tài chính, LLMs đặc biệt hữu ích trong phân tích cảm xúc, đánh giá rủi ro và phát hiện gian lận, bằng cách xử lý khối lượng lớn dữ liệu văn bản để trích xuất thông tin quan trọng và đưa ra dự đoán chính xác. Phân tích cảm xúc tài chính, với mục tiêu nhận diện thái độ tích cực, tiêu cực hoặc trung lập từ các nguồn như bài báo, thông cáo báo chí và bài đăng trên mạng xã hội, đóng vai trò quan trọng trong việc dự báo xu hướng thị trường và hỗ trợ ra quyết định đầu tư [4, 20]. Chẳng hạn, cảm xúc tiêu cực trên mạng xã hội có thể báo hiệu biến động giá cổ phiếu, trong khi cảm xúc tích cực từ báo cáo tài chính củng cố niềm tin đầu tư.

Tuy nhiên, việc khai thác dữ liệu cảm xúc trong tài chính đối mặt với hai thách thức chính: quyền riêng tư và khan hiếm dữ liệu gán nhãn. Dữ liệu thực thường chứa thông tin nhạy cảm như chi tiết tài chính cá nhân hay lịch sử giao dịch, và việc sử dụng mà không có biện pháp bảo vệ thích hợp có thể dẫn đến rủi ro rò rỉ thông tin, gây hậu quả nghiêm trọng về tài chính và pháp lý [6, 24]. Đồng thời, quá trình gán nhãn dữ liệu cảm xúc đòi hỏi kiến thức chuyên sâu và

sự can thiệp thủ công, dẫn đến tốn kém thời gian, công sức, và dễ xảy ra sai lệch do đánh giá chủ quan [1]. Những hạn chế này làm giảm chất lượng dữ liệu huấn luyện, ảnh hưởng đến hiệu suất của các mô hình phân tích cảm xúc và đặt ra yêu cầu về một giải pháp tự động, bảo mật và hiệu quả hơn.

Để giải quyết các thách thức trên, nghiên cứu này đề xuất phương pháp *Reinforcement Prompting*, sử dụng học tăng cường để tối ưu hóa các prompt, từ đó tạo ra dữ liệu tổng hợp chất lượng cao thay thế dữ liệu thực trong phân tích cảm xúc tài chính. Phương pháp này kết hợp Selector và Executor để sinh dữ liệu nhân tạo phản ánh chính xác ngữ cảnh và cảm xúc tài chính, đồng thời đảm bảo quyền riêng tư bằng cách loại bỏ thông tin cá nhân [12, 30]. Dữ liệu tổng hợp không chỉ giảm sự phụ thuộc vào gán nhãn thủ công, tiết kiệm chi phí và thời gian, mà còn nâng cao tính nhất quán và độ tin cậy thông qua quá trình tối ưu hóa gợi ý. Cách tiếp cận này hỗ trợ hiệu quả các ứng dụng phân tích cảm xúc và dự báo xu hướng thị trường trong tài chính hiện đại.

2 Công việc liên quan

Phân tích cảm xúc tài chính đã thu hút nhiều sự chú ý nhờ khả năng trích xuất tín hiệu cảm xúc từ các nguồn dữ liệu văn bản như báo cáo tài chính và bài đăng trên mạng xã hội. Các nghiên cứu liên quan có thể được chia thành ba hướng chính: (1) ứng dụng các mô hình ngôn ngữ lớn (LLMs) trong tài chính, (2) các phương pháp sinh dữ liệu tổng hợp, và (3) sử dụng học tăng cường trong xử lý ngôn ngữ tự nhiên. Phần này xem xét các công trình tiêu biểu và làm rõ đóng góp của phương pháp *Reinforcement Prompting* đề xuất trong nghiên cứu này.

Các mô hình ngôn ngữ lớn như BloombergGPT [29] và FinBERT [3] đã đạt được hiệu suất cao trong phân tích cảm xúc tài chính. BloombergGPT, được huấn luyện trên dữ liệu tài chính độc quyền, vượt trội trong các tác vụ như phân tích cảm xúc và dự báo thị trường, trong khi FinBERT cải thiện độ chính xác khi xử lý văn bản tài chính. Tuy nhiên, cả hai đều yêu cầu lượng lớn dữ liệu thực được gán nhãn, dẫn đến chi phí cao và rủi ro về quyền riêng tư khi sử dụng dữ liệu nhạy cảm [13].

Để giải quyết vấn đề khan hiếm dữ liệu gán nhãn, các kỹ thuật sinh dữ liệu tổng hợp như mạng đối kháng sinh (GANs) [2, 31] và differential privacy [11] đã được khám phá. GANs có thể tạo văn bản tài chính, nhưng thường thiếu tính đa dạng và không tái hiện tốt các sắc thái cảm xúc. Differential privacy bảo vệ quyền riêng tư bằng cách thêm nhiễu, nhưng làm giảm chất lượng dữ liệu, ảnh hưởng đến hiệu suất phân tích cảm xúc. Các phương pháp này chưa giải quyết triệt để bài toán dữ liệu trong tài chính.

Học tăng cường cũng được ứng dụng trong xử lý ngôn ngữ tự nhiên, chẳng hạn như tối ưu hóa văn bản hoặc tinh chỉnh mô hình [9, 33]. Tuy nhiên, việc sử dụng RL để sinh dữ liệu tổng hợp cho phân tích cảm xúc tài chính vẫn còn hạn chế. Một số nghiên cứu gần đây đã khám phá tối ưu hóa gợi ý [25], nhưng chưa tập trung vào các thách thức cụ thể như quyền riêng tư hoặc khan hiếm dữ liệu gán nhãn trong tài chính.

Phương pháp *Reinforcement Prompting* đề xuất trong nghiên cứu này khắc phục các hạn chế trên bằng cách kết hợp học tăng cường với LLMs để tạo dữ liệu tổng hợp chất lượng cao. Không giống như BloombergGPT hay FinBERT, phương pháp của chúng tôi không phụ thuộc vào dữ liệu thực nhạy cảm, đảm bảo quyền riêng tư. So với GANs và differential privacy, *Reinforcement Prompting* tạo dữ liệu phản ánh tốt hơn ngữ cảnh tài chính, đồng thời giảm chi phí gán nhãn thủ công, mang lại một giải pháp hiệu quả và sáng tạo cho phân tích cảm xúc tài chính.

3 Framework Reinforcement Prompting

Framework Reinforcement Prompting là một hệ thống tích hợp được thiết kế để tạo dữ liệu tổng hợp tài chính chất lượng cao, giải quyết các thách thức về khan hiếm dữ liệu thực được gán nhãn và yêu cầu bảo vệ quyền riêng tư trong phân tích cảm xúc tài chính. Bằng cách kết hợp

mô hình ngôn ngữ lớn [5, 8] với học tăng cường, framework này sinh ra các câu văn tài chính có tính thực tiễn, giảm thiểu phụ thuộc vào dữ liệu nhạy cảm

3.1 Thành phần của Framework

Framework bao gồm bốn thành phần chính, phối hợp chặt chẽ để đảm bảo chất lượng dữ liệu tổng hợp:

Keyword Vocabulary : Đây là tập hợp các thuật ngữ tài chính chuyên ngành, được tuyển chọn từ Financial Terminology Glossary (FTG) và kho ngữ liệu của GPT-3.5-turbo. KV bao gồm các từ khóa như “derivatives”, “liquidity”, “volatility”, đóng vai trò là action space cho Selector Agent. Ví dụ, từ khóa “liquidity” có thể được sử dụng để sinh các câu liên quan đến tính thanh khoản trong ngân hàng. KV đảm bảo các prompt tạo ra phản ánh đúng ngữ cảnh tài chính.

Prompt Template : TPL là cấu trúc tĩnh định dạng prompt, ví dụ: “Generate 100 financial sentences related to [keyword], focusing on [context].” TPL đảm bảo tính nhất quán về cú pháp và ngữ nghĩa, cho phép LLM sinh dữ liệu phù hợp với mục tiêu phân tích cảm xúc. Một TPL cụ thể có thể là: “Generate 100 financial sentences related to volatility, focusing on market downturns.”

Selector Agent: Đây là mạng học tăng cường, chịu trách nhiệm chọn các từ khóa từ KV để tạo prompt tối ưu (pmt^*). Selector Agent được huấn luyện dựa trên RL để tối đa hóa phần thưởng tích lũy, phản ánh chất lượng dữ liệu tổng hợp. Ví dụ, Selector Agent có thể chọn “volatility” và kết hợp với TPL để tạo prompt: “Generate 100 financial sentences related to volatility, focusing on stock market fluctuations.” Quá trình huấn luyện dựa trên hàm phần thưởng tổng hợp, chi tiết trong phần sau.

Executor : LLM, như GPT-3.5-turbo, nhận prompt từ Selector Agent và TPL để sinh dữ liệu tổng hợp. Executor tận dụng khả năng xử lý ngôn ngữ tự nhiên để tạo các câu văn tài chính có cấu trúc phức tạp, ngữ nghĩa chính xác, và phù hợp với ngữ cảnh, ví dụ: “High volatility in the stock market has led to cautious investment strategies.”

3.2 Quy trình hoạt động

Framework hoạt động theo quy trình tuần hoàn, như sau:

1. Selector Agent chọn một hoặc nhiều từ khóa từ KV dựa trên chính sách học tăng cường.
2. TPL kết hợp từ khóa để tạo prompt, ví dụ: “Generate 100 financial sentences related to liquidity, focusing on banking stability.”
3. Executor nhận prompt và sinh tập dữ liệu tổng hợp $D = \{d_1, d_2, \dots, d_m\}$, ví dụ: “Increased liquidity has stabilized banking operations during the crisis.”
4. Dữ liệu tổng hợp được đánh giá thông qua hàm phần thưởng, dựa trên các tiêu chí STY, ACR, và LXC.
5. Phần thưởng được sử dụng để cập nhật chính sách của Selector Agent, cải thiện việc chọn từ khóa trong các lần lặp tiếp theo.

3.3 Mục tiêu tối ưu hóa

Mục tiêu chính của framework là xác định prompt tối ưu pmt^* để hướng dẫn LLM tạo dữ liệu tổng hợp chất lượng cao. Vì TPL là cấu trúc tĩnh, pmt^* phụ thuộc vào các từ khóa do Selector Agent chọn từ KV. Quá trình tối ưu hóa sử dụng RL, với lợi nhuận dự kiến được định nghĩa như:

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [R(\tau)],$$

trong đó:

- θ : Tham số của mạng chính sách.
- π_θ : Chính sách chọn từ khóa, xác định xác suất chọn hành động a_t (từ khóa) ở trạng thái s_t (tập từ khóa đã chọn).

- $\tau = (s_0, a_0, s_1, a_1, \dots, s_T, a_T)$: Quỹ đạo hành động trong một episode.
 - $R(\tau)$: Phần thưởng tích lũy, đánh giá chất lượng dữ liệu tổng hợp.
- Tham số θ được cập nhật bằng gradient ascent:

$$\nabla J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \nabla_\theta \log \pi(a_t | s_t; \theta) R(\tau) \right],$$

$$\theta \leftarrow \theta + \alpha \nabla J(\theta),$$

trong đó α là learning rate, điều chỉnh mức độ cập nhật. Giá trị α được chọn cẩn thận để đảm bảo hội tụ ổn định.

3.4 Môi trường và Hàm phần thưởng

Môi trường: Bao gồm Selector Agent và Executor, tạo thành một vòng lặp khép kín. Selector Agent chọn từ khóa (hành động), Executor sinh dữ liệu tổng hợp (kết quả), và phần thưởng được tính để định hướng hành động tiếp theo.

Phần thưởng tức thời (r_t):

- Với các bước không cuối:

$$r_t = r_t(\text{action}) - r_t(\text{penalty}),$$

trong đó $r_t(\text{action})$ là giá trị dương (ví dụ, 0.1) khuyến khích chọn từ khóa mới, và $r_t(\text{penalty})$ là giá trị âm (ví dụ, -0.2) nếu từ khóa trùng lặp, thúc đẩy sự đa dạng.

- Với bước cuối:

$$r_t = r_t(\text{action}) - r_t(\text{penalty}) + r_t(\text{data}),$$

với $r_t(\text{data})$ đánh giá chất lượng dữ liệu tổng hợp:

$$r_t(\text{data}) = v_1 \cdot \text{STY}(D_S, D_R) + v_2 \cdot \text{ACR}(D_S, \text{BERT}(D_R)) + v_3 \cdot \text{LXC}(D_S, \text{FTG}),$$

trong đó:

- $\text{STY}(D_S, D_R)$: Tương đồng phong cách, tính bằng khoảng cách cosine giữa vector biểu diễn văn bản của dữ liệu tổng hợp (D_S) và thực (D_R).
- $\text{ACR}(D_S, \text{BERT}(D_R))$: Độ chính xác cảm xúc, đo bằng hiệu suất của BERT (huấn luyện trên D_R) khi dự đoán cảm xúc trên D_S .
- $\text{LXC}(D_S, \text{FTG})$: Tính mạch lạc và chuyên môn, đo bằng tỷ lệ từ khóa FTG xuất hiện trong D_S .
- v_1, v_2, v_3 : Trọng số, với $v_1 + v_2 + v_3 = 1$.

Phần thưởng tích lũy:

$$R(\tau) = r_1 + \gamma r_2 + \dots + \gamma^{T-1} r_T,$$

trong đó $\gamma \in [0, 1]$ là hệ số chiết khấu, ưu tiên phần thưởng dài hạn.


3.5 Đầu ra của Framework

Framework tạo ra các kết quả sau: Chính sách tối ưu (π^*): Chính sách của Selector Agent, cho phép chọn từ khóa hiệu quả từ KV, tối ưu hóa chất lượng prompt. Prompt tối ưu (pmt^*): Prompt tốt nhất, ví dụ: "Generate 100 financial sentences related to derivatives in the context of risk management." Tập dữ liệu tổng hợp (D): Tập hợp các câu tài chính chất lượng cao, ví dụ: "Derivatives trading has mitigated risks in volatile markets." Tập $D = \{d_1, d_2, \dots, d_m\}$ phù hợp để huấn luyện mô hình học máy, đảm bảo quyền riêng tư và giảm chi phí gán nhãn thủ công [23].

Các đầu ra này hỗ trợ các tác vụ phân tích cảm xúc tài chính, cung cấp dữ liệu tổng hợp chất lượng cao cho huấn luyện mô hình, đồng thời đáp ứng các yêu cầu về bảo mật và hiệu quả [18].

4 Phương pháp

Phần này trình bày chi tiết phương pháp Reinforcement Prompting, một cách tiếp cận sáng tạo để sinh dữ liệu tổng hợp tài chính chất lượng cao, tập trung vào việc giảm phụ thuộc vào dữ liệu thực nhạy cảm và đảm bảo quyền riêng tư. Phương pháp này tận dụng sức mạnh của Large Language Model - LLM kết hợp với học tăng cường để tạo ra các câu văn tài chính phong phú và thực tiễn, phù hợp cho các ứng dụng như phân tích cảm xúc hoặc huấn luyện mô hình học máy. Quy trình tổng quan được minh họa trong Hình 1.



Hình 1: Fig. 1. Framework of financial synthetic data generation via reinforcement prompting.

4.1 Tổng quan phương pháp

Phương pháp Reinforcement Prompting được thiết kế như một hệ thống tích hợp, trong đó dữ liệu tổng hợp tài chính được sinh ra từ sự phối hợp giữa các thành phần chính. Khác với các phương pháp truyền thống phụ thuộc vào dữ liệu thực lớn hoặc quy tắc cố định, cách tiếp cận này bắt đầu từ đầu ra mong muốn – dữ liệu tài chính chất lượng cao – và xây dựng ngược lại quy trình để đạt được mục tiêu đó. Các thành phần bao gồm:

- **Executor** : Đây là trung tâm tạo dữ liệu, nhận các prompt từ hệ thống và sinh ra các câu văn tài chính như báo cáo thị trường, nhận định đầu tư, hoặc phân tích rủi ro. Ví dụ, từ prompt “Analyze market trends in a volatile economy”, Executor có thể tạo ra: “Recent market trends indicate increased volatility due to geopolitical tensions.” Executor tận dụng khả năng hiểu ngữ cảnh và tạo ngôn ngữ tự nhiên của LLM (như GPT-3.5-turbo) để đảm bảo dữ liệu có cấu trúc phức tạp và phù hợp với ngữ cảnh tài chính.
- **Prompt Template - TPL**: Đây là khung ngôn ngữ cố định, định dạng cách từ khóa được tổ chức thành prompt hoàn chỉnh. Một TPL mẫu có thể là: “Generate a financial summary involving [keyword1], [keyword2], and [keyword3] in the current market.” TPL đảm bảo tính nhất quán về cú pháp và ngữ pháp, đồng thời cho phép linh hoạt thay đổi nội dung thông qua từ khóa, giúp Executor sinh ra dữ liệu đa dạng nhưng vẫn có cấu trúc rõ ràng.
- **Keyword Vocabulary - KV**: Tập hợp từ khóa chuyên ngành tài chính, đóng vai trò là nguồn nguyên liệu để xây dựng prompt. KV bao gồm các từ như “profit”, “liquidity”, “derivative”, “inflation”, được lựa chọn để phản ánh ngôn ngữ thực tế trong lĩnh vực tài chính. Từ khóa trong KV không chỉ đảm bảo tính chuyên môn mà còn cung cấp đủ độ phong phú để tránh dữ liệu tổng hợp bị đơn điệu.
- **Selector Agent**: Tác nhân Reinforcement Learning chịu trách nhiệm chọn từ khóa từ KV, quyết định nội dung của prompt. Selector Agent hoạt động như một bộ lọc thông minh, học cách ưu tiên các từ khóa tạo ra prompt hiệu quả nhất (pmt^*), dựa trên phản hồi từ chất lượng dữ liệu tổng hợp. Khác với cách chọn ngẫu nhiên, Selector Agent cải thiện qua từng vòng lặp để đạt được chính sách tối ưu.

Quy trình hoạt động của hệ thống là một chu trình lặp liên tục:

1. Selector Agent chọn một tập từ khóa từ KV dựa trên trạng thái hiện tại (các từ khóa đã chọn trước đó).
2. Từ khóa này được điền vào TPL để tạo prompt, ví dụ: “Generate a financial summary involving profit, risk, and inflation in the current market.”
3. Prompt được gửi đến Executor, sinh ra tập dữ liệu tổng hợp $D = \{d_1, d_2, \dots, d_m\}$.
4. Chất lượng của D được đánh giá, cung cấp phản hồi để Selector Agent điều chỉnh lựa chọn từ khóa, hướng tới pmt^* tối ưu.

Mục tiêu là tạo dữ liệu tổng hợp có độ chính xác cao, ngôn ngữ đa dạng, và sát với thực tế tài chính, đồng thời tránh rủi ro quyền riêng tư bằng cách không sử dụng dữ liệu thực trực tiếp.

4.2 Nguồn từ khóa và cấu trúc prompt

Để đảm bảo prompt mang tính chuyên môn và đa dạng, Keyword Vocabulary - KV được xây dựng cẩn thận từ Financial Terminology Glossary, một nguồn tài liệu tài chính đáng tin cậy (ví dụ: <https://www.investopedia.com/>). KV ban đầu chứa hàng nghìn từ khóa, nhưng để giảm chiều không gian hành động cho Selector Agent, GPT-3.5-turbo được sử dụng để phân loại từ

khóa thành 100 nhóm dựa trên tần suất đồng xuất hiện trong kho dữ liệu huấn luyện của nó. Các nhóm này, ví dụ: “market, volatility, trend” hoặc “profit, loss, revenue”, được xếp hạng theo tần suất xuất hiện, và 100 nhóm hàng đầu được chọn để tạo thành KV cuối cùng. Quá trình này không chỉ giảm độ phức tạp mà còn đảm bảo KV phản ánh ngôn ngữ tài chính thực tế.

Prompt Template - TPL được thiết kế để khai thác tối đa khả năng của Executor. Nghiên cứu thực nghiệm cho thấy GPT-3.5-turbo có thể sinh tối đa 100 câu trong một lần lặp, do đó TPL được định dạng để yêu cầu 100 câu tài chính mỗi episode. Một TPL mẫu là: “Provide 100 financial statements about [keyword1] and [keyword2] in the context of [keyword3].” Ví dụ cụ thể về KV và TPL được trình bày trong Bảng 1.

Keyword Sets	Prompt Template
market, volatility, trend	Provide 100 financial statements about [keyword1] and [keyword2] in the context of [keyword3].
profit, risk, investment	Generate 100 analyses of [keyword1] involving [keyword2] and [keyword3].
equity, liquidity, debt	Summarize [keyword1] impacts on [keyword2] and [keyword3] in 100 sentences.

Bảng 1: Ví dụ về Keyword Sets và Prompt Template trong Reinforcement Prompting.

4.3 Mạng Selector-Executor

Phương pháp triển khai Reinforcement Prompting dựa trên mạng Selector-Executor, một hệ thống tương tác động để tối ưu hóa prompt. Selector Agent, hoạt động như tác nhân Reinforcement Learning, chọn từ khóa (hành động a_t) dựa trên trạng thái hiện tại s_t – tức là tập từ khóa đã chọn trước đó trong episode. Nếu từ khóa chưa xuất hiện, Agent nhận thưởng nhỏ để khuyến khích khám phá; nếu trùng lặp, bị phạt để tránh lặp lại. Episode kết thúc khi Agent chọn token “<end>” hoặc đạt số bước tối đa (ví dụ: 10 bước). Tập từ khóa tích lũy được kết hợp với TPL để tạo prompt hoàn chỉnh, gọi là “Prompt for Executor”.

Executor nhận prompt này và sinh dữ liệu tổng hợp D_S , ví dụ: “Profit margins decreased due to rising investment risks.” Chất lượng D_S được đánh giá bằng cách so sánh với dữ liệu thực D_R , một mô hình BERT tinh chỉnh trên ngữ cảnh tài chính, và Financial Terminology Glossary. Phản hồi từ đánh giá tổng hợp thành phần thưởng cuối cho Selector Agent, định hướng cải thiện qua từng episode. Để tối ưu hóa, Reinforce Algorithm được áp dụng, sử dụng gradient ascent để cập nhật chính sách của Agent:

$$\nabla J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \nabla_\theta \log \pi(a_t | s_t; \theta) R(\tau) \right]. \quad (1)$$

4.4 Đánh giá chất lượng dữ liệu tổng hợp

Chất lượng của dữ liệu tổng hợp D_S được đánh giá bằng cách so sánh với dữ liệu thực D_R và FTG, sử dụng ba số liệu chính:

- **STY (Stylistic Similarity)**: Đo lường sự tương đồng về phong cách giữa D_S và D_R .
- **ACR (Accuracy)**: Đánh giá hiệu suất thực tiễn của D_S thông qua độ chính xác của mô hình phân loại cảm xúc.
- **LXC (Lexical Diversity)**: Đo mức độ đa dạng ngôn ngữ và tính liên quan tài chính của D_S .

Các số liệu này cung cấp cơ sở định lượng để đánh giá hiệu quả của phương pháp và đảm bảo D_S đáp ứng các tiêu chuẩn chất lượng cần thiết.

4.4.1 Số liệu STY (Stylistic Similarity)

Mục đích: Số liệu STY đo lường mức độ tương đồng về phong cách giữa dữ liệu tổng hợp D_S và dữ liệu thực D_R , đảm bảo D_S phản ánh đúng đặc điểm ngôn ngữ của các văn bản tài chính thực tế.

Thành phần:

- $STY_1 = 1 - JSD(P, Q)$, trong đó:
 - P : Phân phối cảm xúc của D_S (tỷ lệ câu tích cực, tiêu cực, trung lập).
 - Q : Phân phối cảm xúc của D_R .
 - $JSD(P, Q) = \frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M)$, với $M = \frac{P+Q}{2}$, và D_{KL} là khoảng cách Kullback-Leibler.
- $STY_2 = \frac{|S \cap R|}{|R|}$, trong đó:
 - $|S \cap R|$: Số từ trong D_S cũng xuất hiện trong D_R .
 - $|R|$: Tổng số từ trong D_R .

Tổng hợp:

$$STY = w_1 \cdot STY_1 + w_2 \cdot STY_2, \quad (2)$$

với $w_1 + w_2 = 1$. Các trọng số w_1 và w_2 có thể được điều chỉnh để cân bằng giữa phân phối cảm xúc và sự tương đồng từ vựng.

4.4.2 Số liệu ACR (Accuracy)

Mục đích: Số liệu ACR đánh giá chất lượng của D_S thông qua độ chính xác của mô hình BERT được huấn luyện trên D_R khi dự đoán cảm xúc trên D_S , phản ánh giá trị thực tiễn của dữ liệu tổng hợp.

Cách tính:

$$ACR = \frac{N_{\text{correct}}(D_S)}{N_{\text{total}}(D_S)}, \quad (3)$$

trong đó:

- $N_{\text{correct}}(D_S)$: Số câu trong D_S được BERT (huấn luyện trên D_R) dự đoán đúng.
- $N_{\text{total}}(D_S)$: Tổng số câu trong D_S .

Một giá trị ACR cao cho thấy D_S có thể thay thế D_R trong các tác vụ phân tích cảm xúc, khẳng định tính hữu ích của dữ liệu tổng hợp.

4.4.3 Số liệu LXC (Lexical Diversity and Financial Relevance)

Mục đích: Số liệu LXC đo lường sự đa dạng ngôn ngữ và mức độ liên quan của D_S đến lĩnh vực tài chính thông qua việc sử dụng các thuật ngữ từ FTG.

Thành phần:

- $LXC_1 = \frac{N_{\text{unique}}(D_S)}{N_{\text{total}}(D_S)}$, trong đó:
 - $N_{\text{unique}}(D_S)$: Số từ duy nhất trong D_S .
 - $N_{\text{total}}(D_S)$: Tổng số từ trong D_S .
- $LXC_2 = \frac{N_{\text{FTG}}(D_S)}{N_{\text{total}}(D_S)}$, trong đó:
 - $N_{\text{FTG}}(D_S)$: Số từ trong D_S thuộc FTG.

Tổng hợp:

$$LXC = u_1 \cdot LXC_1 + u_2 \cdot LXC_2, \quad (4)$$

với $u_1 + u_2 = 1$. Các trọng số u_1 và u_2 có thể được điều chỉnh để cân bằng giữa đa dạng ngôn ngữ và tính chuyên môn.

4.5 Thực Nghiệm Tạo Dữ Liệu Tài Chính Tổng Hợp

Trong tiểu mục này, chúng tôi trình bày chi tiết quy trình thực nghiệm để tạo ra dữ liệu tài chính tổng hợp bằng phương pháp Reinforcement Prompting. Chúng tôi mô tả các nguồn dữ liệu đầu vào, lựa chọn mô hình ngôn ngữ, và các bước triển khai cụ thể để thu được bộ dữ liệu tổng hợp chất lượng cao.

4.5.1 Nguồn Dữ Liệu Tài Chính Thực Tế và Thuật Ngữ Chuyên Ngành

Bộ dữ liệu Financial PhraseBank: Để làm cơ sở so sánh và cung cấp ngữ cảnh thực tế, chúng tôi sử dụng bộ dữ liệu Financial PhraseBank [19]. Bộ dữ liệu này gồm 4.846 câu tin tức tài chính tiếng Anh, được gán nhãn thủ công bởi 16 chuyên gia, đảm bảo tính tin cậy cao cho các đánh giá sau này (ví dụ mẫu trong Bảng ?? – *tham chiếu đến Bảng 3 của bài gốc*).

Financial Terminology Glossary (FTG): Để đảm bảo dữ liệu tổng hợp mang tính chuyên môn, chúng tôi xây dựng một Bảng Thuật Ngữ Tài Chính toàn diện. Nguồn chính bao gồm từ điển tài chính của Investopedia, được bổ sung thêm các ký hiệu chứng khoán từ các sàn giao dịch lớn của Hoa Kỳ (AMEX, NASDAQ, NYSE). FTG này đóng vai trò then chốt trong việc định hướng quá trình tạo prompt và đánh giá chất lượng dữ liệu (ví dụ thuật ngữ trong Bảng ?? – *tham chiếu đến Bảng 4 của bài gốc*).

4.5.2 Lựa Chọn Mô Hình Ngôn Ngữ và Các Thành Phần Hỗ Trợ

Executor LLM: Sau khi đánh giá các lựa chọn như ChatGPT của OpenAI, Claude của Anthropic, và Bard của Google, chúng tôi chọn ChatGPT (cụ thể là kiến trúc `gpt-3.5-turbo`) làm Executor LLM. Lựa chọn này dựa trên khả năng truy cập API dễ dàng, năng lực ngôn ngữ mạnh mẽ và sự phù hợp với mục tiêu tạo dữ liệu tài chính chất lượng cao.

Mô hình tính toán phần thưởng ACR: Để tính toán thành phần ACR (Accuracy) của hàm phần thưởng trong mỗi lượt huấn luyện Agent, chúng tôi sử dụng mô hình FinBERT [3], một mô hình BERT đã được huấn luyện trước trên bộ dữ liệu Financial PhraseBank. Điều này giúp tiết kiệm tài nguyên tính toán so với việc huấn luyện một mô hình BERT từ đầu cho mỗi lần đánh giá.

Mô hình cho tác vụ xuôi dòng: Đối với tác vụ phân tích cảm xúc cuối cùng (đánh giá hiệu quả của dữ liệu tổng hợp), chúng tôi chọn mô hình `bert-base-uncased` chưa được huấn luyện (untrained). Mô hình này sẽ được huấn luyện riêng biệt trên dữ liệu tổng hợp của chúng tôi để đánh giá chất lượng.

4.6 Thực Nghiệm Tạo Dữ Liệu Tài Chính Tổng Hợp

Trong tiểu mục này, chúng tôi trình bày chi tiết quy trình thực nghiệm để tạo ra dữ liệu tài chính tổng hợp bằng phương pháp Reinforcement Prompting. Chúng tôi mô tả các nguồn dữ liệu đầu vào, lựa chọn mô hình ngôn ngữ, và các bước triển khai cụ thể để thu được bộ dữ liệu tổng hợp chất lượng cao.

4.6.1 Nguồn Dữ Liệu Tài Chính Thực Tế và Thuật Ngữ Chuyên Ngành

Bộ dữ liệu Financial PhraseBank: Để làm cơ sở so sánh và cung cấp ngữ cảnh thực tế, chúng tôi sử dụng bộ dữ liệu Financial PhraseBank [19]. Bộ dữ liệu này gồm 4.846 câu tin tức

tài chính tiếng Anh, được gán nhãn thủ công bởi 16 chuyên gia, đảm bảo tính tin cậy cao cho các đánh giá sau này.

Financial Terminology Glossary (FTG): Để đảm bảo dữ liệu tổng hợp mang tính chuyên môn, chúng tôi xây dựng một Bảng Thuật Ngữ Tài Chính toàn diện. Nguồn chính bao gồm từ điển tài chính của Investopedia, được bổ sung thêm các ký hiệu chứng khoán từ các sàn giao dịch lớn của Hoa Kỳ (AMEX, NASDAQ, NYSE). FTG này đóng vai trò then chốt trong việc định hướng quá trình tạo prompt và đánh giá chất lượng dữ liệu.

4.6.2 Lựa Chọn Mô Hình Ngôn Ngữ và Các Thành Phần Hỗ Trợ

Executor LLM: Sau khi đánh giá các lựa chọn như ChatGPT của OpenAI, Claude của Anthropic, và Bard của Google, chúng tôi chọn ChatGPT (cụ thể là kiến trúc `gpt-3.5-turbo`) làm Executor LLM. Lựa chọn này dựa trên khả năng truy cập API dễ dàng, năng lực ngôn ngữ mạnh mẽ và sự phù hợp với mục tiêu tạo dữ liệu tài chính chất lượng cao.

Mô hình tính toán phần thưởng ACR: Để tính toán thành phần ACR (Accuracy) của hàm phần thưởng trong mỗi lượt huấn luyện Agent, chúng tôi sử dụng mô hình FinBERT [3], một mô hình BERT đã được huấn luyện trước trên bộ dữ liệu Financial PhraseBank. Điều này giúp tiết kiệm tài nguyên tính toán so với việc huấn luyện một mô hình BERT từ đầu cho mỗi lần đánh giá.


Mô hình cho tác vụ xuôi dòng: Đối với tác vụ phân tích cảm xúc cuối cùng (đánh giá hiệu quả của dữ liệu tổng hợp), chúng tôi chọn mô hình `bert-base-uncased` chưa được huấn luyện (untrained). Mô hình này sẽ được huấn luyện riêng biệt trên dữ liệu tổng hợp của chúng tôi để đánh giá chất lượng.

4.6.3 Triển Khai Reinforcement Prompting và Tạo Dữ Liệu

Quá trình triển khai phương pháp Reinforcement Prompting để tạo dữ liệu tổng hợp bao gồm các bước chính:

1. Huấn luyện Selector Agent:

- Agent được khởi tạo với một bộ từ vựng gồm các tập từ khóa tài chính tần suất cao, chọn lọc từ Investopedia và dữ liệu huấn luyện trước của ChatGPT.
- Trong quá trình huấn luyện lặp, Agent chọn các tập từ khóa, kết hợp với Mẫu Prompt (Prompt Template) đã định nghĩa trước để tạo ra các prompt.
- Executor LLM (`gpt-3.5-turbo` với thiết lập nhiệt độ thấp) sử dụng các prompt này để tạo ra các mẫu dữ liệu tổng hợp thử nghiệm.
- Chúng tôi thực hiện tổng cộng 1.000 chu kỳ (episode) huấn luyện. Quá trình hội tụ của Agent, thể hiện qua phần thưởng tích lũy, được minh họa trong hình dưới đây:



Hình 2: Reinforcement prompting cumulative rewards for each episode.

Hình này cho thấy sự ổn định sau khoảng 650 chu kỳ.

2. Xác định Prompt Tối Ưu và Tạo Dữ Liệu Tổng Hợp Cuối Cùng:

- Sau khi huấn luyện, chính sách tối ưu của Agent giúp chọn ra các từ khóa hiệu quả nhất.
- Những từ khóa này được sử dụng để tạo một prompt toàn diện, tối ưu.
- Prompt tối ưu này sau đó được đưa vào Executor LLM (`gpt-3.5-turbo`, lần này với thiết lập nhiệt độ cao hơn) để tạo ra một bộ dữ liệu tài chính tổng hợp đa dạng gồm 2.300 mẫu.

Bộ dữ liệu tổng hợp thu được từ quy trình thực nghiệm này sau đó được sử dụng cho tác vụ phân tích cảm xúc xuôi dòng để đánh giá hiệu quả của nó so với dữ liệu thực.

5 Kết Quả

5.1 Kết quả của việc triển khai Reinforcement Prompting

Chúng tôi triển khai phương pháp Reinforcement Prompting với Agent ban đầu được trang bị một bộ từ vựng được tuyển chọn gồm các tập từ khóa có tần suất cao. Những từ khóa này được chọn dựa trên thuật ngữ tài chính từ Investopedia và dữ liệu huấn luyện trước của ChatGPT [5].

Trong quá trình lặp của Reinforcement Prompting, Agent chọn các tập từ khóa trong mỗi lượt huấn luyện và tự nhiên kết hợp chúng với một mẫu prompt được xác định trước. Những prompt được tạo ra thông qua quá trình này sau đó hướng dẫn LLM thực thi để tạo ra các mẫu synthetic data.¹ Đối với giai đoạn huấn luyện, chúng tôi sử dụng GPT-3.5-turbo với thiết lập nhiệt độ thấp để đảm bảo phần thưởng ổn định ở bước cuối cùng của mỗi lượt huấn luyện.

Chúng tôi đặt tổng số lượt huấn luyện là 1.000, nhằm đạt được sự cân bằng giữa việc khám phá rộng rãi và tối ưu hóa, đồng thời xem xét các ràng buộc về tính toán. Hình ?? mô tả phần thưởng tích lũy cho mỗi lượt huấn luyện, cho thấy rằng quá trình huấn luyện ổn định sau khoảng 650 lượt huấn luyện.

Bảng 2 trình bày các từ khóa được chọn thông qua quá trình Reinforcement Prompting. Những từ khóa được chọn này cung cấp cái nhìn sâu sắc về chất lượng của các prompt được tạo ra, đóng vai trò là bằng chứng bổ sung cho hiệu quả của phương pháp.

¹Synthetic data: dữ liệu tổng hợp, được tạo ra bởi các mô hình thay vì thu thập từ nguồn thực tế.

Bảng 2: Selected keyword sets.

Keywords
Business Valuation, Book Value, Market Value, Liquidation Value, Replacement Value Market Research, Qualitative Research, Quantitative Research, Market Segmentation, Target Market American Industrial

Một prompt toàn diện, như được hiển thị trong Bảng 3, sau đó được sử dụng để hướng dẫn GPT-3.5-turbo nhiều lần. Trái ngược với giai đoạn huấn luyện, ở đây chúng tôi sử dụng thiết lập nhiệt độ cao để khuyến khích việc tạo ra các điểm dữ liệu synthetic data tài chính đa dạng. Các mẫu synthetic data kết quả có thể được sử dụng thêm cho các nhiệm vụ tiếp theo.

Bảng 3: Generated prompt for executor.

Optimal Prompt
- Market Research, Qualitative Research, Quantitative Research, Market Segmentation, Target Market - Financial Derivatives, Options, Futures, Swaps, Forward Contracts, Counterparty Risk - Annuities, Ordinary Annuity, Annuity Due, Perpetuity, Present Value of Annuity - Personal Finance, Budget, Savings, Expenses, Income, Emergency Fund, Credit Card

6 Phân tích Cảm xúc : một nhiệm vụ tiếp theo

Trong giai đoạn tiếp theo của nghiên cứu, chúng tôi triển khai prompt tối ưu, thu được thông qua phương pháp Reinforcement Prompting, để hướng dẫn LLM thực thi trong việc tạo ra 2.300 mẫu synthetic data tài chính. Với những synthetic data đó, chúng tôi tiến hành một nhiệm vụ phân tích cảm xúc tiếp theo, so sánh hiệu suất của các mô hình BERT được huấn luyện trên synthetic data và dữ liệu thực từ Financial Phrasebank, tương ứng. Các so sánh được thực hiện bằng cách sử dụng Bộ dữ liệu Tài chính Twitter và Bộ dữ liệu Tài chính Fin-news. Do hạn chế về số lượng ký tự đầu ra do API của OpenAI áp đặt, chúng tôi thực hiện nhiều lần lặp prompting để tích lũy đủ lượng synthetic data. Một tập con của các mẫu được tạo ra này được trình bày trong Bảng 4.

Bảng 4: Samples of the generated financial synthetic dataset via reinforcement prompting.

Sentence	Label
The company's earnings report exceeded expectations, leading to a surge in stock prices.	positive
Due to the recent market volatility, investors are advised to exercise caution.	negative
The central bank's decision to lower interest rates could stimulate economic growth.	positive
The merger between the two companies is expected to create synergies and increase market share.	neutral
The economic downturn has led to a decrease in consumer spending.	negative
The new tax policy is likely to impact small businesses adversely.	neutral
The stock market rally continued for the third consecutive day.	positive
The company's debt levels are a cause for concern among analysts.	negative

Để cung cấp cái nhìn sâu sắc hơn về bản chất của các mẫu synthetic data được tạo ra, trước tiên chúng tôi phân tích các đặc điểm của bộ dữ liệu thực. Bộ dữ liệu Financial PhraseBank, như được hiển thị trong Bảng 3, thể hiện một số đặc điểm chính:

- Độ phức tạp của các trường hợp văn bản: Các câu có cấu trúc đa dạng, từ những tuyên bố đơn giản đến các mô tả phức tạp hơn liên quan đến nhiều mệnh đề. - Đa dạng từ vựng: Bộ dữ liệu bao gồm thuật ngữ tài chính cụ thể và từ vựng đa dạng. - Nhân cảm xúc đa dạng: Các câu được gắn nhãn với cảm xúc tích cực, trung lập hoặc tiêu cực, phản ánh một loạt các ý kiến và giọng điệu.

Bộ synthetic data của chúng tôi, được trình bày trong Bảng 4, phản ánh những đặc điểm này. Các câu tổng hợp thể hiện độ phức tạp cấu trúc câu và đa dạng từ vựng tương tự, kết hợp các bối cảnh và thuật ngữ tài chính cụ thể, và các nhân cảm xúc đa dạng. Sự phù hợp này đảm bảo rằng synthetic data duy trì được tính hữu ích và sự phong phú của dữ liệu thực, làm cho nó phù hợp cho các nhiệm vụ tiếp theo.

Thiết kế thí nghiệm của chúng tôi bao gồm việc huấn luyện hai mô hình BERT riêng biệt trên các bộ dữ liệu ngày càng lớn hơn, cả synthetic data và bộ dữ liệu thực Financial Phrasebank. Những bộ dữ liệu này chứa lần lượt 1.000, 1.100, 1.200, 1.300, 1.400, 1.500, 1.600, 1.700 và 1.812 mẫu. Mỗi bộ dữ liệu huấn luyện được tuyển chọn cẩn thận để duy trì sự phân bố cân bằng của các cảm xúc tích cực, tiêu cực và trung lập. Do Financial Phrasebank là một bộ dữ liệu có sẵn, số lượng tối đa các câu cân bằng có thể thu được là 1.812, do đó đặt ra giới hạn trên cho các mẫu huấn luyện. Để nâng cao hiệu suất mô hình, 10% của mỗi bộ dữ liệu huấn luyện được phân bổ cho việc xác thực. Để kiểm tra, chúng tôi sử dụng Bộ dữ liệu Tài chính Twitter và Bộ dữ liệu Tài chính Fin-news, cả hai đều có thể truy cập tại <https://www.huggingface.com>.

6.1 Phân tích trên Bộ dữ liệu Tài chính Twitter

Chúng tôi đánh giá hiệu suất của các mô hình BERT được huấn luyện trên synthetic data (BERT-Syn) và bộ dữ liệu Financial Phrasebank (BERT-Real) bằng cách sử dụng Bộ dữ liệu Tài chính Twitter làm bộ dữ liệu kiểm tra. Bộ dữ liệu này được cắt giảm còn 5.064 điểm dữ liệu từ 11.882 mẫu để duy trì sự phân bố cân bằng của các cảm xúc tích cực, tiêu cực và trung lập. Các chỉ số đánh giá của chúng tôi bao gồm độ chính xác, độ chính xác (precision) và độ nhạy (recall), và chúng tôi xem xét các kích thước mẫu huấn luyện khác nhau từ 1.000 đến 1.812. Những chỉ số này cho cả hai mô hình BERT được hiển thị trong Bảng 5, 6, và 7. Phân tích này nhằm cung cấp một đánh giá toàn diện về tính hữu ích và độ tin cậy của synthetic data và dữ liệu thực cho phân tích cảm xúc tài chính trong bối cảnh mạng xã hội.

Tóm tắt độ chính xác tổng thể được trình bày trong Bảng 5. Quan sát từ bảng cho thấy rằng BERT-Syn liên tục vượt trội so với BERT-Real trên các kích thước bộ huấn luyện khác nhau khi được kiểm tra trên Bộ dữ liệu Tài chính Twitter. Cụ thể, BERT-Syn đạt độ chính xác cao nhất là 0,67 với kích thước bộ huấn luyện là 1.500 điểm dữ liệu, trong khi BERT-Real đạt đỉnh ở 0,64 với 1.600 điểm dữ liệu. Điều thú vị là mô hình BERT-Syn thể hiện hiệu suất tương đối ổn định, với độ chính xác dao động từ 0,59 đến 0,67. Ngược lại, BERT-Real thể hiện một chút biến thiên lớn hơn, dao động từ 0,53 đến 0,64. Điều này gợi ý rằng synthetic data có thể cung cấp một tín hiệu huấn luyện nhất quán hơn cho mô hình.

Bảng 5: Sentiment analysis accuracy comparison: BERT Models Trained on Generated Synthetic Data (BERT-Syn) vs. Financial Phrasebank Real Data (BERT-Real), tested on a balanced twitter financial dataset comprising 5064 data points, equally distributed across sentiment labels.

Accuracy	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn	0.65	0.64	0.59	0.66	0.66	0.67	0.63	0.65	0.64
BERT-Real	0.56	0.57	0.53	0.56	0.55	0.58	0.64	0.53	0.57

Các mô hình BERT được tinh chỉnh bằng cách sử dụng một số lượng mẫu hạn chế (từ 1.000 đến 1.812) của synthetic data hoặc dữ liệu thực từ Financial Phrasebank. Hiệu suất của chúng được đánh giá trên Bộ dữ liệu Tài chính Twitter, mà các mô hình tinh chỉnh chưa từng thấy trước đó. Mục tiêu của nghiên cứu này khác với các công trình trước đây, chẳng hạn như những

công trình liên quan đến FinBERT cho phân tích cảm xúc tài chính (Araci (2019); Huang et al. (2022)), nơi các mô hình thường được tinh chỉnh trước trên một kho dữ liệu tài chính lớn và sau đó được huấn luyện và kiểm tra trong cùng một lĩnh vực. Do đó, hiệu suất của kết quả của chúng tôi (Bảng 5)—nơi các mô hình được huấn luyện và kiểm tra trên hai bộ dữ liệu khác nhau—tự nhiên thấp hơn so với các mô hình FinBERT được huấn luyện và kiểm tra trên cùng một bộ dữ liệu (Bộ dữ liệu Tài chính Twitter). Mục tiêu chính của chúng tôi là đánh giá hiệu quả của synthetic data được tạo ra thông qua Reinforcement Prompting để huấn luyện các mô hình BERT trong phân tích cảm xúc tài chính. Để đạt được điều này, chúng tôi thiết kế các thí nghiệm để kiểm tra khả năng của các mô hình trong việc thực hiện trên các kho văn bản tài chính khác nhau (các bộ dữ liệu kiểm tra trong các phân phối khác nhau). Không giống như các mô hình FinBERT, các mô hình BERT của chúng tôi không được tinh chỉnh trước trên bất kỳ dữ liệu tài chính nào trước khi được tinh chỉnh trên các mẫu synthetic data hoặc thực. Cách tiếp cận này cung cấp một kịch bản huấn luyện thực tế và thách thức hơn. Hơn nữa, chúng tôi tinh chỉnh các mô hình BERT bằng cách sử dụng một lượng nhỏ dữ liệu để mô phỏng các điều kiện thực tế nơi các mẫu dữ liệu tài chính thường khan hiếm do các mối quan ngại về quyền riêng tư và vấn đề truy cập. Những yêu cầu này tự nhiên dẫn đến kết quả độ chính xác thấp hơn. Tuy nhiên, độ chính xác thấp hơn này là điều được mong đợi và cần thiết, vì BERT được huấn luyện trên bộ dữ liệu Financial Phrasebank thực tương đương (BERT-Real) cũng có hiệu suất độ chính xác thấp tương tự. Bằng cách thiết kế các thí nghiệm theo cách này, chúng tôi nhằm đảm bảo rằng synthetic data có thể hữu ích trên nhiều bộ dữ liệu khác nhau, làm cho chúng có giá trị trong các bối cảnh tài chính khác nhau nơi dữ liệu thực bị hạn chế hoặc khó thu thập. Điều này chứng minh rằng cách tiếp cận của chúng tôi cung cấp một đánh giá thực tế và thực tiễn về hiệu quả của synthetic data, nhấn mạnh tiềm năng của nó cho việc áp dụng rộng rãi hơn thay vì chỉ tối ưu hóa cho một bộ dữ liệu duy nhất.

Bảng 6 chi tiết các điểm số độ chính xác (precision) cho các danh mục cảm xúc khác nhau khi được đánh giá trên Bộ dữ liệu Tài chính Twitter. Cả hai mô hình BERT-Syn và BERT-Real đều thể hiện hiệu suất tương tự trong việc xác định các cảm xúc "Tích cực". Tuy nhiên, BERT-Syn thường vượt trội hơn BERT-Real trong việc nắm bắt các cảm xúc "Tiêu cực", đạt điểm số độ chính xác cao nhất là 0,87 với bộ huấn luyện gồm 1.400 điểm dữ liệu. Đối với các cảm xúc "Trung lập", cả hai mô hình đều thể hiện điểm số độ chính xác tương đối thấp hơn, với BERT-Syn hơi vượt trội hơn BERT-Real.

Bảng 6: Precision scores of different sentiments comparison: BERT Models Trained on Generated Synthetic Data (BERT-Syn) vs. Financial Phrasebank Real Data (BERT-Real), tested on a balanced twitter financial dataset comprising 5064 data points, equally distributed across sentiment labels.

Precision	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn "Positive"	0.69	0.69	0.81	0.57	0.69	0.62	0.83	0.68	0.56
BERT-Real "Positive"	0.69	0.76	0.63	0.65	0.48	0.76	0.73	0.59	0.72
BERT-Syn "Negative"	0.78	0.83	0.86	0.74	0.87	0.81	0.85	0.83	0.83
BERT-Real "Negative"	0.80	0.70	0.86	0.78	0.81	0.84	0.73	0.86	0.78
BERT-Syn "Neutral"	0.54	0.53	0.46	0.78	0.55	0.64	0.40	0.54	0.64
BERT-Real "Neutral"	0.45	0.45	0.43	0.45	0.52	0.42	0.52	0.44	0.45

Bảng 7 minh họa các điểm số độ nhạy (recall) cho Bộ dữ liệu Tài chính Twitter. Trong trường hợp các cảm xúc "Tích cực" và "Tiêu cực", các chỉ số độ nhạy của BERT-Syn nói chung tương đương hoặc tốt hơn so với BERT-Real. Tuy nhiên, đối với các cảm xúc "Trung lập", BERT-Real thể hiện độ nhạy cao hơn, đạt đỉnh ở 0,91 với bộ huấn luyện gồm 1.500 điểm dữ liệu. Quan sát này cho thấy BERT-Real có thể nhạy hơn với các cảm xúc trung lập trong bộ dữ liệu.

Bảng 7: Recall scores of different sentiments comparison: BERT Models Trained on Generated Synthetic Data (BERT-Syn) vs. Financial Phrasebank Real Data (BERT-Real), tested on a balanced twitter financial dataset comprising 5064 data points, equally distributed across sentiment labels.

Recall	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn "Positive"	0.64	0.65	0.65	0.88	0.67	0.77	0.46	0.63	0.78
BERT-Real "Positive"	0.46	0.45	0.43	0.41	0.68	0.50	0.51	0.55	0.41
BERT-Syn "Negative"	0.59	0.46	0.40	0.66	0.50	0.52	0.52	0.52	0.51
BERT-Real "Negative"	0.36	0.40	0.31	0.42	0.41	0.59	0.68	0.30	0.47
BERT-Syn "Neutral"	0.72	0.80	0.91	0.44	0.81	0.67	0.90	0.79	0.65
BERT-Real "Neutral"	0.85	0.86	0.81	0.80	0.87	0.91	0.72	0.74	0.82

6.2 Phân tích trên Bộ dữ liệu Tài chính Fin-news

Chúng tôi mở rộng phân tích của mình để đánh giá hiệu suất của các mô hình BERT được huấn luyện trên synthetic data (BERT-Syn) và dữ liệu thực Financial Phrasebank (BERT-Real) khi được kiểm tra trên Bộ dữ liệu Tài chính Fin-news. Bộ dữ liệu này bao gồm 2.103 điểm dữ liệu từ 8.675 mẫu, với sự phân bố cân bằng trên ba lớp tình cảm: tích cực, tiêu cực và trung lập. Các chỉ số được xem xét bao gồm độ chính xác, độ chính xác (precision) và độ nhạy (recall) trên các số lượng mẫu huấn luyện khác nhau (1.000, 1.100, 1.200, 1.300, 1.400, 1.500, 1.600, 1.700, 1.812). Kết quả được mô tả trong Bảng 8, 9, và 10.

Kết quả độ chính xác trên Bộ dữ liệu Tài chính Fin-news, như được tóm tắt trong Bảng 8, cho thấy các mẫu khác biệt so với những gì quan sát được trên Bộ dữ liệu Tài chính Twitter. Cả BERT-Syn và BERT-Real đều thể hiện hiệu suất dao động với các kích thước bộ huấn luyện khác nhau. BERT-Real đạt độ chính xác cao nhất là 0,90 với các bộ huấn luyện gồm 1.600 và 1.812 điểm dữ liệu, trong khi BERT-Syn đạt đỉnh ở 0,84 với 1.300 điểm dữ liệu.

Bảng 8: Sentiment analysis accuracy comparison: BERT Models Trained on Generated Synthetic Data (BERT-Syn) vs. Financial Phrasebank Real Data (BERT-Real), tested on a balanced fin-news financial dataset comprising 2103 data points, equally distributed across sentiment labels.

Accuracy	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn	0.82	0.64	0.57	0.84	0.73	0.78	0.79	0.75	0.74
BERT-Real	0.72	0.72	0.70	0.75	0.81	0.85	0.90	0.60	0.90

Điều thú vị là BERT-Real vượt trội hơn BERT-Syn khi được huấn luyện trên các bộ dữ liệu lớn hơn (1.500, 1.600 và 1.812), ngụ ý rằng dữ liệu tài chính thực có thể cung cấp một biểu diễn đặc trưng tinh tế hơn cho bộ dữ liệu kiểm tra cụ thể này.

Bảng 9 chi tiết các điểm số độ chính xác (precision) cho các cảm xúc khác nhau trên Bộ dữ liệu Tài chính Fin-news. Đối với các cảm xúc "Tích cực", cả hai mô hình đều cho thấy hiệu suất cạnh tranh, nhưng BERT-Syn nổi bật ở các kích thước bộ huấn luyện trung bình (1.300-1.500). Trong trường hợp các cảm xúc "Tiêu cực", cả hai mô hình đều hoạt động xuất sắc, nhưng BERT-Real hơi vượt trội hơn BERT-Syn. Đối với các cảm xúc "Trung lập", BERT-Real nói chung cho thấy độ chính xác cao hơn, đặc biệt ở các kích thước bộ huấn luyện lớn hơn.

Điểm số độ nhạy (recall), như được trình bày trong Bảng 10, cung cấp những hiểu biết bổ sung cho kết quả kiểm tra trên Bộ dữ liệu Tài chính Fin-news. BERT-Syn và BERT-Real đều cho thấy điểm số độ nhạy cao cho các cảm xúc "Tích cực" và "Trung lập", nhưng BERT-Real nói chung vượt trội hơn BERT-Syn đối với các cảm xúc "Tiêu cực", đặc biệt ở các kích thước bộ huấn luyện lớn hơn.

Sự khác biệt về hiệu suất giữa bộ dữ liệu này và Bộ dữ liệu Tài chính Twitter có thể được quy cho các yếu tố sau:

Bảng 9: Precision scores of different sentiments comparison: BERT Models Trained on Generated Synthetic Data (BERT-Syn) vs. Financial Phrasebank Real Data (BERT-Real), tested on a balanced fin-news financial dataset comprising 2103 data points, equally distributed across sentiment labels.

Precision	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn "Positive"	0.80	0.90	0.90	0.74	0.90	0.91	0.93	0.84	0.63
BERT-Real "Positive"	0.91	0.91	0.61	0.60	0.67	0.95	0.91	0.50	0.92
BERT-Syn "Negative"	0.92	0.98	0.94	0.92	0.97	0.96	0.96	0.97	0.98
BERT-Real "Negative"	0.98	0.95	0.98	0.97	0.99	0.98	0.95	1.00	0.95
BERT-Syn "Neutral"	0.76	0.48	0.64	0.91	0.57	0.63	0.63	0.60	0.76
BERT-Real "Neutral"	0.56	0.55	0.63	0.78	0.88	0.72	0.86	0.65	0.84

Bảng 10: Recall scores of different sentiments comparison: BERT Models Trained on Generated Synthetic Data (BERT-Syn) vs. Financial Phrasebank Real Data (BERT-Real), tested on a balanced fin-news financial dataset comprising 2103 data points, equally distributed across sentiment labels.

Recall	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn "Positive"	0.84	0.51	0.50	0.93	0.58	0.60	0.64	0.78	0.91
BERT-Real "Positive"	0.64	0.73	0.88	0.90	0.95	0.98	0.86	0.94	0.85
BERT-Syn "Negative"	0.83	0.45	0.27	0.94	0.67	0.79	0.77	0.58	0.61
BERT-Real "Negative"	0.59	0.47	0.67	0.87	0.85	0.82	0.86	0.62	0.98
BERT-Syn "Neutral"	0.80	0.96	0.95	0.67	0.95	0.94	0.95	0.88	0.70
BERT-Real "Neutral"	0.94	0.94	0.55	0.47	0.64	0.98	0.90	0.66	0.92

- Đặc điểm của bộ dữ liệu: Dữ liệu Financial Phrasebank, được sử dụng để huấn luyện các mô hình, có cấu trúc và phân bố tương tự hơn với Bộ dữ liệu Tài chính Fin-news, so với Bộ dữ liệu Tài chính Twitter. Sự tương đồng này cho phép các mô hình được huấn luyện trên Financial Phrasebank hoạt động tốt hơn khi được kiểm tra trên Bộ dữ liệu Tài chính Fin-news. - Bản chất của dữ liệu Twitter: Ngược lại, Bộ dữ liệu Tài chính Twitter bao gồm các tweet thường ngắn hơn, ít cấu trúc hơn và chứa nhiều ngôn ngữ không chính thức. Sự phân bố của các cảm xúc và phong cách văn bản trong dữ liệu Twitter khác biệt đáng kể so với định dạng có cấu trúc của các bài báo tin tức. Kết quả là, các mô hình được huấn luyện trên Financial Phrasebank hoặc synthetic data có thể gặp khó khăn trong việc tổng quát hóa tốt trên Bộ dữ liệu Tài chính Twitter, dẫn đến hiệu suất thấp hơn so với khi kiểm tra trên Bộ dữ liệu Tài chính Fin-news.

6.3 Phân tích về độ biến thiên

Đối với cả kết quả độ chính xác của Bộ dữ liệu Tài chính Twitter (Bảng 5) và Bộ dữ liệu Tài chính Fin-news (Bảng 8), độ biến thiên giữa một số kết quả có xu hướng lớn đối với các số lượng mẫu huấn luyện khác nhau. Ví dụ, trong Bảng 5, BERT-Real đạt 0,53 về độ chính xác khi được tinh chỉnh với 1.500 mẫu dữ liệu, đạt 0,64 về độ chính xác khi được tinh chỉnh với 1.600 mẫu dữ liệu, sau đó giảm xuống 0,53 một lần nữa với 1.700 mẫu dữ liệu. Để phân tích nguyên nhân của độ biến thiên này, chúng tôi lặp lại các thí nghiệm về việc tinh chỉnh các mô hình BERT với các số lượng mẫu huấn luyện khác nhau, và chúng tôi quan sát thấy độ biến thiên này hiện diện trong mỗi lần chạy của thí nghiệm. Dựa trên những quan sát này, chúng tôi có thể rút ra các kết luận sau:

- Ảnh hưởng của kích thước mẫu: Nguyên nhân chính của độ biến thiên này là kích thước mẫu nhỏ được sử dụng để huấn luyện. Trong các kịch bản với dữ liệu hạn chế, hiệu suất của mô hình có thể bị ảnh hưởng đáng kể bởi các đặc điểm cụ thể của các mẫu huấn luyện, dẫn đến độ biến thiên cao hơn. Đây là một hiện tượng được công nhận rộng rãi trong nghiên cứu học máy,

nơi các bộ dữ liệu nhỏ hơn thường dẫn đến các mô hình ít ổn định hơn. - Độ biến thiên trong dữ liệu thực: Điều quan trọng cần lưu ý là độ biến thiên này không chỉ xuất hiện ở synthetic data; nó cũng được quan sát thấy trong các mô hình được huấn luyện trên dữ liệu thực. Để minh họa điều này, chúng tôi đã tiến hành nhiều thí nghiệm sử dụng cả synthetic data được tạo ra và dữ liệu thực từ Bộ dữ liệu Financial Phrasebank, sau đó kiểm tra chúng trên Bộ dữ liệu Tài chính Twitter. Bảng 11 trình bày kết quả độ chính xác từ ba lần chạy khác nhau của thí nghiệm, làm nổi bật sự biến thiên vốn có. - Hiệu suất trung bình: Để giảm thiểu tác động của độ biến thiên này, chúng tôi đã tính trung bình kết quả của 30 lần chạy cho mỗi kích thước mẫu huấn luyện cho các thí nghiệm trên Bộ dữ liệu Tài chính Twitter. Bảng 12 trình bày kết quả độ chính xác trung bình, cho thấy hiệu suất của các mô hình được huấn luyện trên synthetic data gần khớp với những mô hình được huấn luyện trên dữ liệu thực. Điều này chứng minh chất lượng cao của synthetic data được tạo ra thông qua phương pháp Reinforcement Prompting.

Bảng 11: Accuracy results from multiple runs on twitter financial dataset.

Accuracy	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn Run 1	0.65	0.64	0.59	0.65	0.65	0.67	0.63	0.65	0.64
BERT-Syn Run 2	0.66	0.64	0.67	0.67	0.68	0.68	0.64	0.66	0.65
BERT-Syn Run 3	0.64	0.67	0.68	0.69	0.69	0.69	0.64	0.64	0.65
BERT-Real Run 1	0.56	0.57	0.53	0.55	0.55	0.53	0.64	0.53	0.57
BERT-Real Run 2	0.63	0.56	0.55	0.59	0.57	0.57	0.63	0.64	0.68
BERT-Real Run 3	0.58	0.62	0.59	0.57	0.54	0.59	0.52	0.57	0.55

Bảng 12: Average sentiment analysis accuracy comparison BERT Models Trained on Generated Synthetic Data (BERT-Syn) vs. Financial Phrasebank Real Data (BERT-Real), tested on a balanced twitter financial dataset comprising 5064 data points, equally distributed across sentiment labels.

Accuracy	1000	1100	1200	1300	1400	1500	1600	1700	1812
BERT-Syn	0.66	0.65	0.60	0.64	0.66	0.68	0.66	0.67	0.67
BERT-Real	0.57	0.61	0.58	0.59	0.51	0.59	0.62	0.60	0.61

Những quan sát này cho thấy rằng độ biến thiên chủ yếu là do kích thước mẫu nhỏ được sử dụng để huấn luyện chứ không phải do bản chất của synthetic data. Bằng cách tính trung bình kết quả qua nhiều lần chạy, chúng tôi có thể thu được một đánh giá đáng tin cậy hơn về hiệu suất của mô hình, từ đó xác nhận hiệu quả của synthetic data của chúng tôi.

6.4 Nghiên cứu trường hợp: Đánh giá của con người

Chúng tôi đã tiến hành một nghiên cứu trường hợp so sánh các bộ dữ liệu thực và synthetic data về chất lượng cú pháp và ngữ nghĩa. Đánh giá này nhằm đánh giá độ tin cậy và hiệu quả của synthetic data được tạo ra.

6.4.1 Thiết lập đánh giá của con người

Chúng tôi chọn 1.000 câu mẫu từ cả bộ dữ liệu thực Financial Phrasebank và bộ synthetic data được tạo ra. Một nhóm gồm ba người đánh giá có chuyên môn về văn bản tài chính được yêu cầu đánh giá các mẫu này dựa trên các tiêu chí sau:

- Tính mạch lạc ngữ nghĩa: Sự nhất quán logic và ý nghĩa của các câu. - Mức độ liên quan đến lĩnh vực: Tính áp dụng và liên quan của các câu đối với lĩnh vực tài chính.

Các nhà đánh giá được hướng dẫn để đánh giá mỗi câu trên thang điểm từ 1 đến 5 cho mỗi tiêu chí, trong đó 1 biểu thị chất lượng kém và 5 biểu thị chất lượng tuyệt vời. Tất cả các nhà

đánh giá tham gia vào quá trình xử lý dữ liệu cho nghiên cứu này đã được thông báo về bản chất của nghiên cứu và đồng ý cho phép sử dụng các đánh giá của họ. Quá trình này được xác nhận là được miễn phê duyệt đạo đức, và sự tham gia của họ hoàn toàn tự nguyện.

6.4.2 Đồng thuận của nhà đánh giá và kết quả

Để định lượng sự đồng thuận giữa các nhà đánh giá, chúng tôi tính toán điểm trung bình cho mỗi tiêu chí. Kết quả được tóm tắt trong Bảng 13.

Bảng 13: Annotator agreement on real and synthetic datasets.

Metric	Synthetic Data	Real Data
Semantic Coherence	4.3	4.5
Domain Relevance	4.1	4.2

Các điểm số cho thấy synthetic data gần khớp với chất lượng của dữ liệu thực về tính mạch lạc ngữ nghĩa và mức độ liên quan đến lĩnh vực.

6.5 Dữ liệu tổng hợp so với dữ liệu thực: Tóm tắt so sánh

Chúng tôi tiến hành một phân tích toàn diện về các mô hình BERT được huấn luyện trên synthetic data (BERT-Syn) và dữ liệu tài chính thực từ Financial Phrasebank (BERT-Real), đánh giá hiệu suất của chúng trên hai bộ dữ liệu kiểm tra riêng biệt: Bộ dữ liệu Tài chính Twitter và Bộ dữ liệu Tài chính Fin-news. Các thí nghiệm của chúng tôi cho thấy rằng các mô hình BERT được huấn luyện trên synthetic data thể hiện các chỉ số hiệu suất không chỉ tương đương mà đôi khi còn vượt trội hơn so với các mô hình được huấn luyện trên dữ liệu tài chính thực trong bối cảnh các nhiệm vụ phân tích cảm xúc (xem Bảng 5 và 8).

Những quan sát thực nghiệm của chúng tôi nhấn mạnh một số lợi thế của việc sử dụng synthetic data:

- Tính nhất quán: Như được chứng minh bởi Bộ dữ liệu Tài chính Fin-news, BERT-Syn thể hiện ít biến động hơn trong các chỉ số độ chính xác, cho thấy một tín hiệu huấn luyện ổn định hơn.

- Tính linh hoạt: Các thí nghiệm của chúng tôi chứng minh rằng synthetic data cho phép thử nghiệm rộng rãi với các mẫu cân bằng, điều này rất quan trọng khi dữ liệu thực khan hiếm. Cụ thể trong các thí nghiệm của chúng tôi, chúng tôi tạo ra nhiều bộ synthetic data và chọn các mẫu cân bằng để huấn luyện, giúp đạt được các đánh giá hiệu suất đáng tin cậy và công bằng hơn.

- Hiệu quả chi phí: Việc tạo ra synthetic data thường được chứng minh là kinh tế hơn so với việc thu thập và chú thích dữ liệu thực tế, đặc biệt trong các lĩnh vực chuyên biệt như tài chính.

Tuy nhiên, cũng cần thừa nhận những lợi thế của việc sử dụng dữ liệu thực:

- Tính xác thực: Dữ liệu thực vốn phản ánh sự phân bố và độ phức tạp thực sự của các kịch bản thực tế, đảm bảo rằng các mô hình được huấn luyện trên dữ liệu như vậy được điều chỉnh tốt với các sự kiện thực tế.

- Đa dạng: Dữ liệu thực bao gồm toàn bộ phạm vi biến thiên được tìm thấy trong các văn bản tài chính thực tế, nắm bắt các sự kiện hiếm gặp và các trường hợp ngoại lệ mà synthetic data có thể bỏ sót.

- Cân nhắc pháp lý và tuân thủ: Sử dụng dữ liệu thực giúp đảm bảo rằng các mô hình tuân thủ các tiêu chuẩn quy định và yêu cầu tuân thủ, điều này rất quan trọng trong các lĩnh vực nhạy cảm như tài chính.

- Sự tin tưởng và chấp nhận: Các mô hình được huấn luyện trên dữ liệu thực có thể được xem là đáng tin cậy hơn và được chấp nhận hơn bởi các bên liên quan, vì chúng dựa trên thông tin thực tế, có thể kiểm chứng.

Tóm lại, trong khi synthetic data mang lại những lợi ích đáng kể về tính nhất quán, tính linh hoạt và hiệu quả chi phí, dữ liệu thực vẫn rất quan trọng vì tính xác thực, sự đa dạng, tuân thủ và sự tin tưởng của các bên liên quan. Một cách tiếp cận cân bằng tận dụng cả synthetic data và dữ liệu thực có thể tối đa hóa thế mạnh của mỗi loại, dẫn đến các mô hình mạnh mẽ và linh hoạt hơn cho các nhiệm vụ phân tích cảm xúc trong lĩnh vực tài chính.

7 Kết Luận

7.1 Tổng hợp các đóng góp chính của nghiên cứu

Báo cáo này đã trình bày một cách tiếp cận mới, Reinforcement Prompting, nhằm giải quyết các thách thức liên quan đến dữ liệu trong phân tích cảm xúc tài chính. Cách tiếp cận này sử dụng mô hình học tăng cường để tối ưu hóa quá trình lựa chọn prompt, từ đó giúp mô hình ngôn ngữ lớn sinh ra dữ liệu tổng hợp có độ chính xác cao hơn. So với các phương pháp truyền thống, Reinforcement Prompting mang lại lợi thế đáng kể trong việc bảo vệ quyền riêng tư, giảm sự phụ thuộc vào dữ liệu thực và tạo ra dữ liệu linh hoạt hơn để huấn luyện mô hình.

Các thí nghiệm thực nghiệm cho thấy dữ liệu tổng hợp được tạo ra bằng phương pháp này có thể đạt hiệu suất tương đương dữ liệu thực trong bài toán phân tích cảm xúc. Điều này chứng minh rằng Reinforcement Prompting không chỉ giúp giải quyết bài toán khan hiếm dữ liệu mà còn có tiềm năng ứng dụng rộng rãi trong các bài toán liên quan đến tài chính và kinh doanh.

7.2 Vai trò của phương pháp trong bối cảnh tài chính hiện đại

Trong bối cảnh tài chính hiện đại, dữ liệu đóng vai trò quan trọng trong việc xây dựng các mô hình dự báo và phân tích thị trường. Tuy nhiên, các rào cản về quyền riêng tư, tính bảo mật và chi phí thu thập dữ liệu thực tế khiến việc sử dụng dữ liệu trở thành một thách thức. Phương pháp Reinforcement Prompting mang lại giải pháp tiềm năng khi có thể tạo ra dữ liệu tổng hợp có chất lượng cao, đáp ứng nhu cầu huấn luyện mô hình mà không làm lộ thông tin nhạy cảm.

Bên cạnh đó, với sự phát triển nhanh chóng của các mô hình ngôn ngữ lớn và các ứng dụng AI trong tài chính, việc tối ưu hóa cách mô hình học từ dữ liệu tổng hợp sẽ ngày càng trở nên quan trọng. Reinforcement Prompting có thể đóng vai trò như một công cụ hỗ trợ hữu ích trong nhiều lĩnh vực, từ phân tích cảm xúc thị trường, đánh giá rủi ro tín dụng, đến dự báo xu hướng tài chính. Sự kết hợp giữa học tăng cường và mô hình ngôn ngữ mở ra nhiều cơ hội nghiên cứu và ứng dụng mới, góp phần nâng cao hiệu quả của các hệ thống AI trong ngành tài chính.

Tóm lại, Reinforcement Prompting không chỉ cung cấp một giải pháp khả thi để tạo dữ liệu tổng hợp mà còn mang lại tiềm năng lớn trong các ứng dụng tài chính hiện đại, giúp các tổ chức tài chính khai thác sức mạnh của AI một cách hiệu quả và an toàn hơn.

Tài liệu

- [1] Alissa, K., Alzoubi, O. (2022). Financial sentiment analysis based on transformers and majority voting. *2022 IEEE/ACS 19th International Conference on Computer Systems and Applications (AICCSA)*. DOI: <https://doi.org/10.1109/AICCSA56895.2022.10017775>
- [2] Antoniou, A., Storkey, A., Edwards, H. (2017). Data augmentation generative adversarial networks. *arXiv preprint arXiv:1711.04340*. <https://arxiv.org/abs/1711.04340>
- [3] Araci, D. (2019). FinBERT: Financial sentiment analysis with pre-trained language models. *arXiv preprint arXiv:1908.10063*. <https://arxiv.org/abs/1908.10063>
- [4] Awatramani, P., Daware, R., Chouhan, H., Vaswani, A., Khedkar, S. (2021). Sentiment analysis of mixed-case language using natural language processing. *2021 Third International*

Conference on Inventive Research in Computing Applications (ICIRCA). DOI: <https://doi.org/10.1109/ICIRCA51532.2021.9544937>

- [5] Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901. <https://proceedings.neurips.cc/paper/2020/file/1457c0d6bfc4967418bfb8ac142f64a-Paper.pdf>
- [6] Bryant, R., Cintas, C., Wambugu, I., Kinai, A., Weldemariam, K. (2019). Analyzing bias in sensitive personal information used to train financial models. *arXiv preprint arXiv:1911.03623*. <https://arxiv.org/abs/1911.03623>
- [7] Deng, X., Bashlovkina, V., Han, F., Baumgartner, S., Bendersky, M. (2023). What do LLMs know about financial markets? A case study on Reddit market sentiment analysis. *Companion Proceedings of the ACM Web Conference 2023*. DOI: <https://doi.org/10.1145/3543873.3587324>
- [8] Devlin, J., Chang, M.-W., Lee, K., Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 1, 4171–4186. DOI: <https://doi.org/10.18653/v1/N19-1423>
- [9] Dognin, P., Padhi, I., Melnyk, I., Das, P. (2021). ReGen: Reinforcement learning for text and knowledge base generation using pretrained language models. *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. DOI: <https://doi.org/10.18653/v1/2021.emnlp-main.83>
- [10] Donahue, D., Rumshisky, A. (2018). Adversarial text generation without reinforcement learning. *arXiv preprint arXiv:1810.06640*. <https://arxiv.org/abs/1810.06640>
- [11] Dwork, C. (2006). Differential privacy. *Automata, Languages and Programming*, 4052, 1–12. DOI: https://doi.org/10.1007/11787006_1
- [12] Efimova, V., Shalamov, V., Filchenkov, A. (2020). Synthetic dataset generation for text recognition with generative adversarial networks. *Twelfth International Conference on Machine Vision (ICMV 2019)*, 11433. DOI: <https://doi.org/10.1117/12.2559714>
- [13] Gururangan, S., Marasović, A., Swayamdipta, S., Lo, K., Beltagy, I., Downey, D., Smith, N. A. (2020). Don't stop pretraining: Adapt language models to domains and tasks. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 8342–8360. DOI: <https://doi.org/10.18653/v1/2020.acl-main.740>
- [14] Hoffmann, J., Borgeaud, S., Mensch, A., Buchatskaya, E., Cai, T., Rutherford, E., Casas, D. d. L., Hendricks, L. A., Welbl, J., Clark, A., et al. (2022). Training compute-optimal large language models. *arXiv preprint arXiv:2203.15556*. <https://arxiv.org/abs/2203.15556>
- [15] Huang, A., Wang, H., Yang, Y. (2022). FinBERT: A large language model for extracting information from financial text. *Contemporary Accounting Research*, 40. DOI: <https://doi.org/10.1111/1911-3846.12832>
- [16] Ji, Y., Zhang, Z., Tang, X., Shen, J., Zhang, X., Yang, G. (2022). Detecting cash-out users via dense subgraphs. *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. DOI: <https://doi.org/10.1145/3534678.3539252>

- [17] Lu, D., Wu, H., Liang, J., Xu, Y., He, Q., Geng, Y., Han, M., Xin, Y., Xiao, Y. (2023). BBT-Fin: Comprehensive construction of Chinese financial domain pre-trained language model, corpus and benchmark. *arXiv preprint arXiv:2302.09432*. <https://arxiv.org/abs/2302.09432>
- [18] Lu, Y., Huang, X., Dai, Y., Maharjan, S., Zhang, Y. (2020). Blockchain and federated learning for privacy-preserved data sharing in industrial IoT. *IEEE Transactions on Industrial Informatics*, 16, 4177–4186. DOI: <https://doi.org/10.1109/TII.2019.2942190>
- [19] Malo, P., Sinha, A., Korhonen, P., Wallenius, J., Takala, P. (2014). Good debt or bad debt: Detecting semantic orientations in economic texts. *Journal of the Association for Information Science & Technology*, 65, 782–796. <https://ideas.repec.org/a/bla/jinfst/v65y2014i4p782-796.html>
- [20] Mishra, S., Choubey, S., Choubey, A., Yogeesh, N., Rao, J. D. P., William, P. (2022). Data extraction approach using natural language processing for sentiment analysis. *2022 International Conference on Automation, Computing and Renewable Systems (ICACRS)*. DOI: <https://doi.org/10.1109/ICACRS55517.2022.10029146>
- [21] Narayanan, A., Shmatikov, V. (2008). Robust de-anonymization of large sparse datasets. *2008 IEEE Symposium on Security and Privacy (SP 2008)*, 111–125. DOI: <https://doi.org/10.1109/SP.2008.33>
- [22] Presotto, R., Ek, S., Civitarese, G., Portet, F., Lalanda, P., Bettini, C. (2023). Combining public human activity recognition datasets to mitigate labeled data scarcity. *arXiv preprint arXiv:2306.13735*. <https://arxiv.org/abs/2306.13735>
- [23] Sixt, L., Wild, B., Landgraf, T. (2016). RenderGAN: Generating realistic labeled data. *Frontiers in Robotics and AI*, 5. <https://www.frontiersin.org/articles/10.3389/frobt.2018.00066>
- [24] Truong, A., Walters, A., Goodsitt, J. (2020). Sensitive data detection with high-throughput neural network models for financial institutions. *arXiv preprint arXiv:2012.09597*. <https://arxiv.org/abs/2012.09597>
- [25] Upadhyay, B., Sudhakar, A., Maheswaran, A. (2022). Efficient reinforcement learning for unsupervised controlled text generation. *arXiv preprint arXiv:2204.07696*. <https://arxiv.org/abs/2204.07696>
- [26] Vaswani, A., Shazeer, N., Parmar, N., Uszoreit, J., Jones, L., Gomez, A. N., Kaiser, L., Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30. <https://proceedings.neurips.cc/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf>
- [27] Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *arXiv preprint arXiv:2201.11903*. <https://arxiv.org/abs/2201.11903>
- [28] Weng, W., Pratama, M., Za'in, C., de Carvalho, M., Appan, R., Ashfahani, A., Yee, E. Y. K. (2022). Autonomous cross domain adaptation under extreme label scarcity. *IEEE Transactions on Neural Networks and Learning Systems*, 1–12. DOI: <https://doi.org/10.1109/TNNLS.2022.3183356>
- [29] Wu, S., Irsoy, O., Lu, S., Dabrowski, V., Dredze, M., Gehrmann, S., Kambadur, P., Rosenberg, D., Mann, G. (2023). BloombergGPT: A large language model for finance. *arXiv preprint arXiv:2303.17564*. <https://arxiv.org/abs/2303.17564>

- [30] Wu, Z., Wang, L., Wang, W., Shi, T., Chen, A., Hao, S., Li, S. (2022). Synthetic data supervised salient object detection. *Proceedings of the 30th ACM International Conference on Multimedia*. DOI: <https://doi.org/10.1145/3503161.3547917>
- [31] Xie, L., Lin, K., Wang, S., Wang, F., Zhou, J. (2018). Differentially private generative adversarial network. *arXiv preprint arXiv:1802.06739*. <https://arxiv.org/abs/1802.06739>
- [32] Yang, H., Liu, X. Y., Wang, C. D. (2023). FinGPT: Open-source financial large language models. *arXiv preprint arXiv:2306.06031*. <https://arxiv.org/abs/2306.06031>
- [33] Zhang, M., Tian, G., Gao, H., Zhang, Y. (2022). Autonomous generation of service strategy for household tasks: A progressive learning method with a priori knowledge and reinforcement learning. *IEEE Transactions on Circuits and Systems for Video Technology*, 32, 7473–7488. DOI: <https://doi.org/10.1109/TCSVT.2022.3189357>